

RISC-V走向数据中心之路

武汉元石智算科技有限公司

2024.08

Agenda

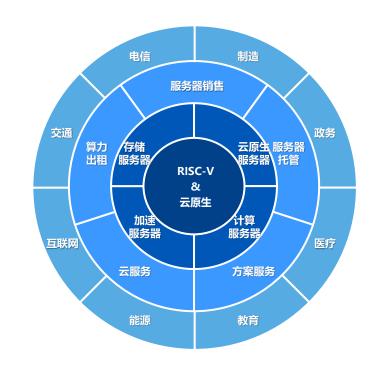


- 关于元石智算
- RISC-V的发展及数据中心的演化
- 元石智算RISC-V跨架构云原生平台
- 观察与展望
- 元石智算核心研发平台

元石智算: RISC-V云原生服务器与解决方案提供商 MetaStone

武汉元石智算科技有限公司 MetaStone

- 打造 "MetaStone" 自主品牌计算/AI/存储系统级服务器、云原生POD等产品
- 提供安全可控的RISMA™跨架构计算集群和多元算力解决方案,以及智算中心、工业、政务等行业解决方案
- 总部位于武汉,在北京、上海设有基地,分别为华中区、华北区、华东区区域总部

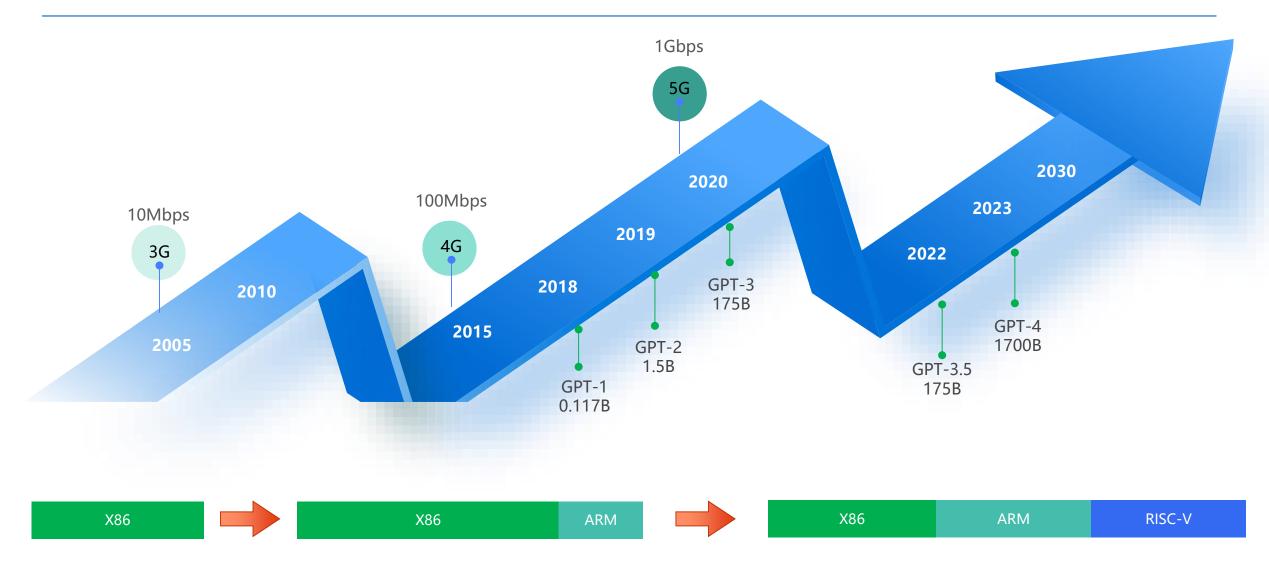




值得信赖的新一代RISC-V云原生服务器与解决方案提供商

RISC-V将在数据中心演化中的角色





第一步: 元石智算云原生跨架构集群

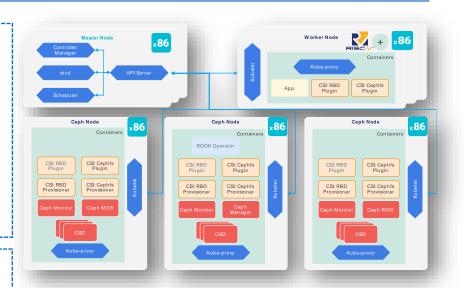


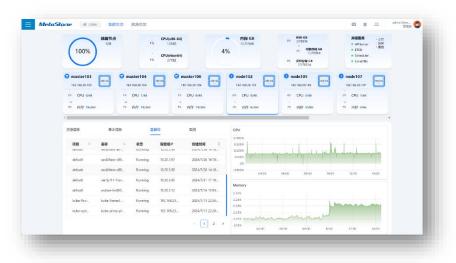




网络 RISC-V X86 存算 云原生跨架构 POD Computer

- 硬件驱动优化
- 完善构建工具链
- 参与OpenEuler RISC-V SIG社 区生态,加固RISC-V服务器操 作系统
- Kubernetes组件RISC-V移植
- 主流开源存储客户端移植
- 多元算力支持
- 自研开发跨架构云原生OS
- 数据中心集群交付

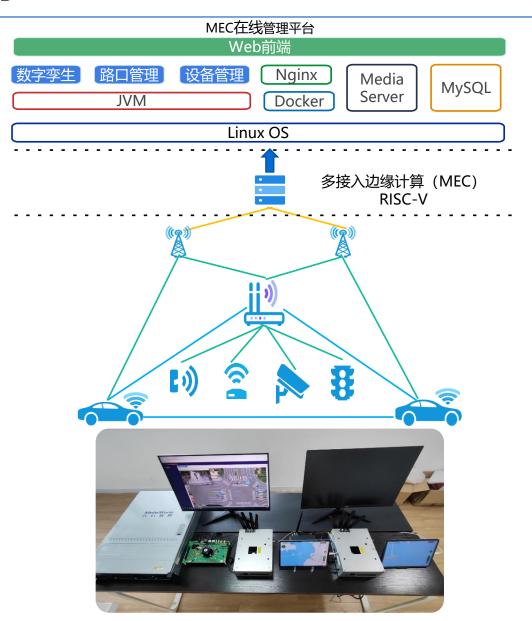




元石智算RISC-V跨架构集群应用案例

Meta5tone







更强的CPU Chiplets 异构 DSA加速器 Vector Hypervisor RAS Security



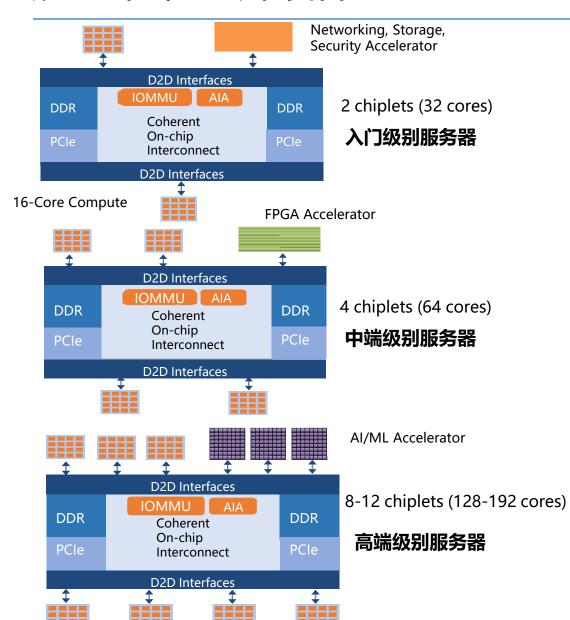
基于Vector的加速库 规模应用的检验 容器镜像



行业的共同努力协作 标准制定

展望未来:芯片硬件



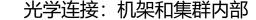


- · Chiplet 构建可扩展的架构数据中心的服务器级别的计算
- 标准芯粒可以组合成所需的解决方案, 且交付周期短
- 可以在所需的 CPU、内存和加速器配置之间切换
- 可选择标准 IO Hub 或带有集成功能的定制 IO Hub
- IO Hub 和定制加速器可以在 N-1/N-2 工艺节点上设计, 以提高成本效益。
- · 芯片发布可以缩短为一年以内
- 研发费用可以相对与monolithic die 大幅降低

展望未来:系统硬件

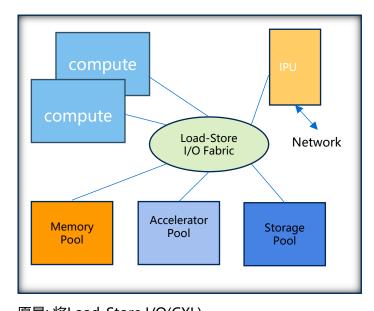
MetaStone

UCle



UCle

UCle



愿景: 将Load-Store I/O(CXL)

作为集群中的结构,提供低延迟和高带宽的资源池化/共 享以及消息传递功能



TORS Memory/ Accelerator Compute Compute Compute 计算盒子

Retimer Retimer Retimer CXL 2.0+ CXL 2.0+ **SWITCH Die SWITCH Die** 内存/加速盒子 (Pooled/Shared Memory) (PooledAccelerator)

Mem Mem **CPU CPU UCle** UCle Retimer Mem Mem **CPU** 1/0

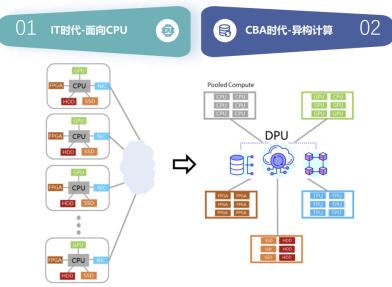
通过UCIe Retimer (例如,共封装光学器件)使用长距离介质 (电气/光学等) 连接CXL机架/集群级别。物理连接通过基于 UCIe Retimer的共封装光学器件 实现 (例如光学、电缆、毫米波)的封装外扩展选项

使用UCIe Retimer实现封装外连接,实现机架/集群级别的资源池化共享

- 不同于之前的数据中心, AI数据中心包含4种不同网络, 其中加速器网络尚处于发展早期, 不同厂家有不同的选择, 从而蕴藏着标准化的机会
 - 带外网络 (BMC管理网络)
 - 前端网络(普通以太网,用于SLURM/Kubernetes、网络存储、数据加载、模型检查点等)
 - 后端网络 (InfiniBand/RoCE以太网,用于扩展数百到数千个机架之间的GPU-GPU通信)
 - 加速器网络(如Nvidia的NVLink、AMD的Infinity Fabric/UALink、Googel的ICI等)

• 基于DPU (Data Processing Unit) 的智能网卡是CBA (Cloud Computing, Big Data, AI) 时代数据中心基 础架 构变革的必要条件

网络	带宽 (Blackwell NVL72)
以太网	18 * 400Gpbs
InfiniBand	72 * 800Gbps
NVLink	72*1.8TBps = 130TBps



展望未来: AI对数据中心的影响—存储



• 当前AI大模型训练耗时长,中断频繁,从而对于数据加载和模型检查点存储提出了更高要求

% of Training Time

在规定时间内完成检查点 Checkpoint 的聚合写带宽(GiB/sec)

		70 Of Hairling Time			
Model Size (B Parameters)	Checkpolnt Size(GIB)	1%	2%	5%	10%
1	13.0	0.18	0.09	0.04	0.02
5	65.2	0.91	0.45	0.18	0.09
10	130.4	1.81	0.91	0.36	0.18
20	260.8	3.62	1.81	0.72	0.36
40	521.5	7.24	3.62	1.45	0.72
175	2281.7	31.6 9	15.85	6.34	3.71
530	6910.4	95.9 8	47.99	19.2	9.60

{AI (III) 服务器虚拟化 实时分析 AI/ML Ethernet(1-10Gb/s) RDMA (100-400Gb/s) CIFS / NFS / FTP / HDFS / iSCSI / S3 / RBD **MOD** Interface 块存储 文件存储 对象存储 元数据服务 数据服务 S3 / POSIX DOD 统一存储平台(第二存储) MOD高速并行文件系统(第一存储) - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 | - 000 — ••• — ••• — ••• — ••• 240TiB NVMe NVMe NVMe NVMe NVMe Sata SSD NVMe R

- 针对智算中心对存储的需求,元石智算的存储系统提供 热层和温层的分层存储,用户通过元石智算MOD并行文 件系统,访问高速存储池时,可以看到所有热层和温层 的数据,根据用户的使用情况,平滑地流动。
- 同时,温层的数据可以对外提供块、对象、文件的统一存储并支持多租户访问,数据保护快照,WORM等企业级feature,以满足智算中心对存储的各类需求。

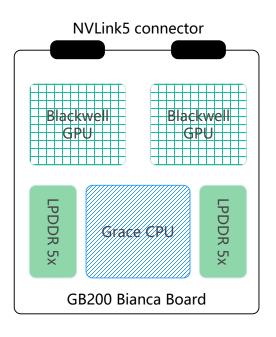
假定:

- 每两小时做一次Checkpoint
- 2 bytes每个模型参数 (BF16)
- 12 bytes每个模型参数用于优化或其他状态

展望未来: AI对数据中心的影响—计算



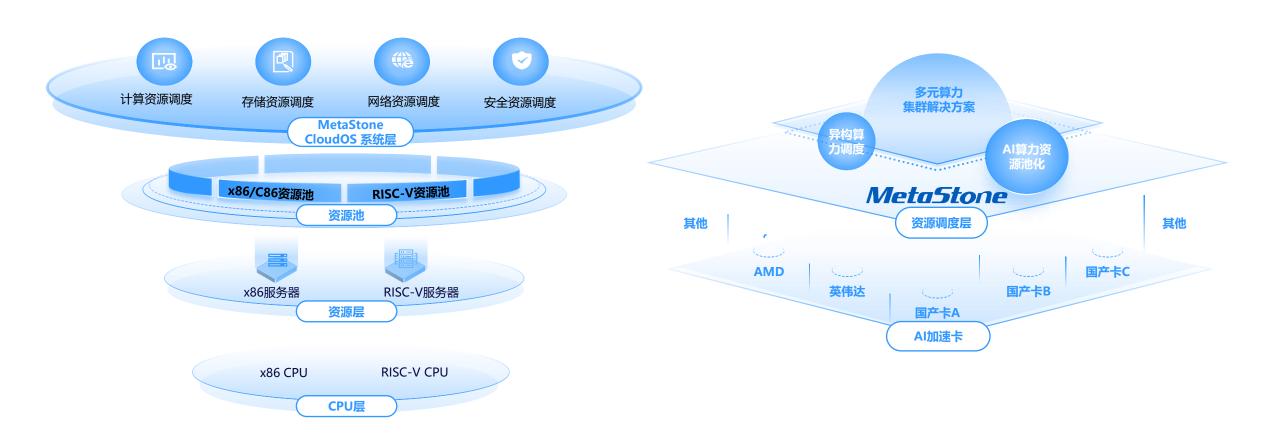
- AI时代各种加速器不断涌现,CPU作为计算机系统中的核心地位(尤其是大模型训练场景中)被打破,需要思考匹配加速器的处理器而非匹配处理器的加速器
 - GB200 NVL72的CPU与GPU的比率是1:2
 - HGX H100的CPU与GPU的比率是2:8
 - GH200的CPU与GPU的比率是1:1, 但GH200的出货量显著低于HGX H100
- 多元芯片纳管, GPU资源池化, 提供对异构算力控制平面和数据平面能力, 用户单一界面管理整个数据中心异构算力资源





元石智算 RISMA™ 跨架构计算集群方案

元石智算多元算力集群方案



MetaStone

Thanks

武汉元石智算科技有限公司

WUHAN METASTONE TECHNOLOGIES INC.

www.metastonecorp.com



元石智算

微信扫描二维码, 关注我的公众号

