香山处理器昆明湖架构向量扩展的设计与演进

刘威丁[2,3] 胡轩[1] 张林隽[2] 张梓悦[1] 王郅尊[2] 冯浩原[1] 肖飞豹[2]
贾志杰[1] 唐浩晋[1] 刘泽昊[1]

[1]中国科学院计算技术研究所 [2]北京开源芯片研究院
[3]南京理工大学

2024 年 8 月 22 日

目录

- 背景介绍
- 香山向量扩展设计
- 高性能向量扩展设计演进
- 总结

目录

背景：SIMD

- SISD：单指令单数据
  - 单条指令处理**单个**数据
  - 标量处理器
- SIMD：单指令多数据
  - 单条指令处理**多个**数据
  - 向量处理机
  - 提高计算并行度
  - 适用于图像/信号处理等应用

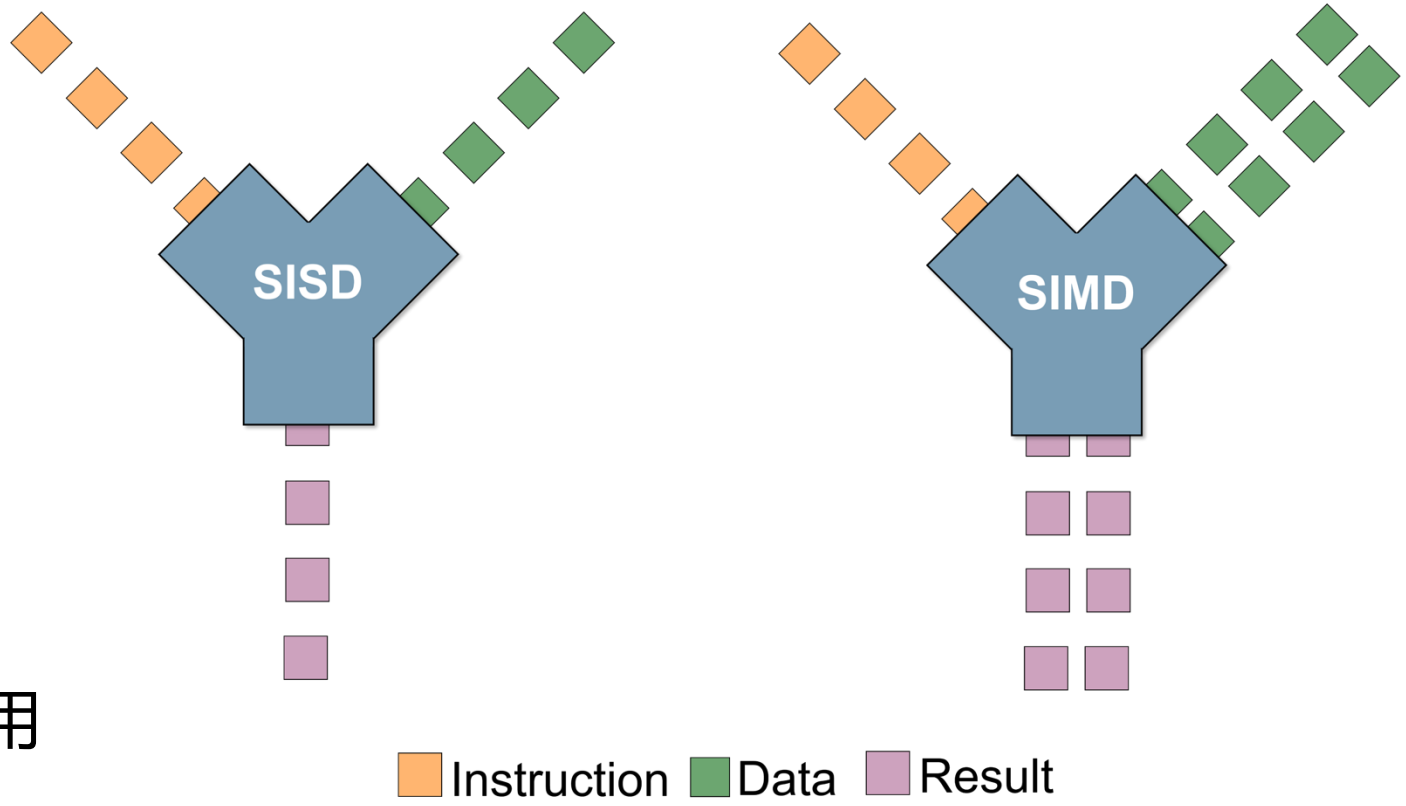

背景：SIMD

- 传统的 SIMD 使用**特定向量长度**，对应特定的向量**寄存器位宽**
  - 软件使用短向量长度 + 硬件长 SIMD → **寄存器等硬件资源浪费**
  - 软件使用长向量长度 + 硬件短 SIMD → **程序并行度低**

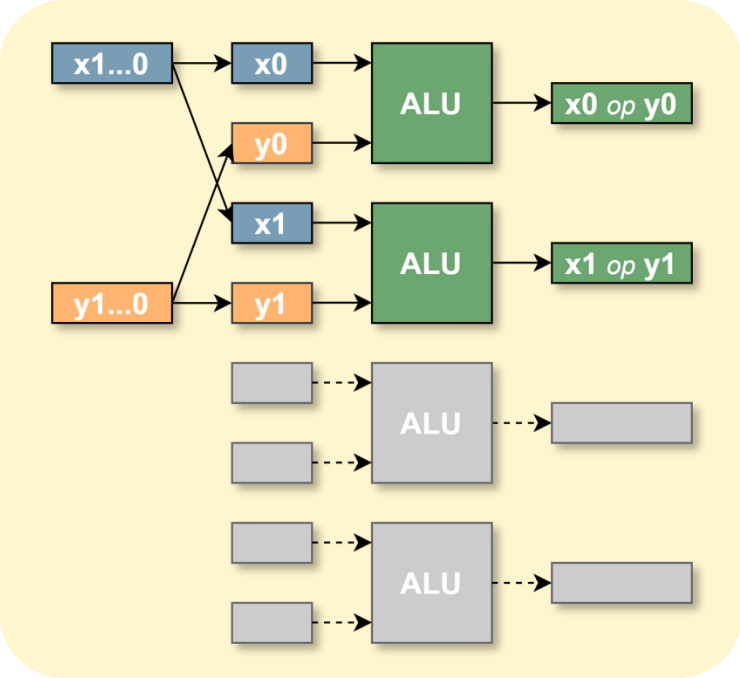

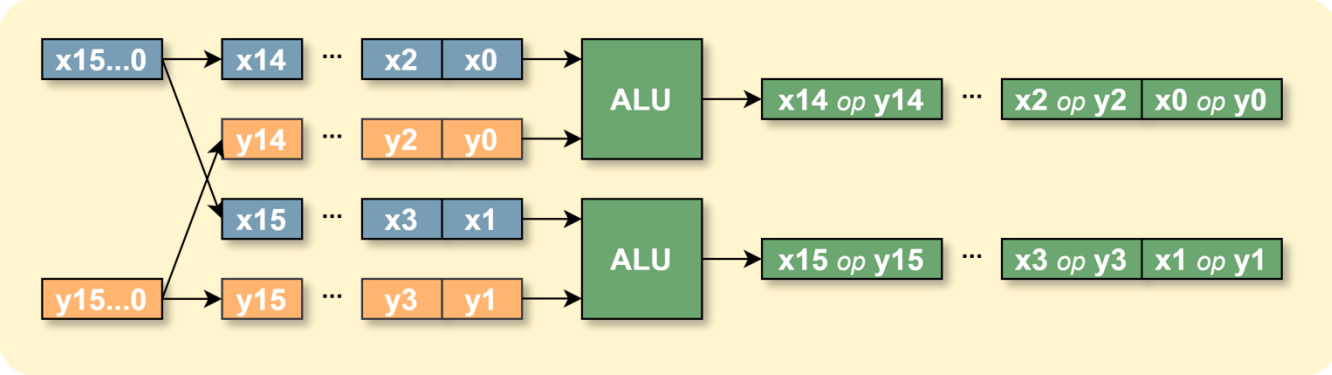

背景：RISC-V 向量计算技术

- **寄存器组**：一条指令操作多个向量寄存器 → **提高运算并行度**

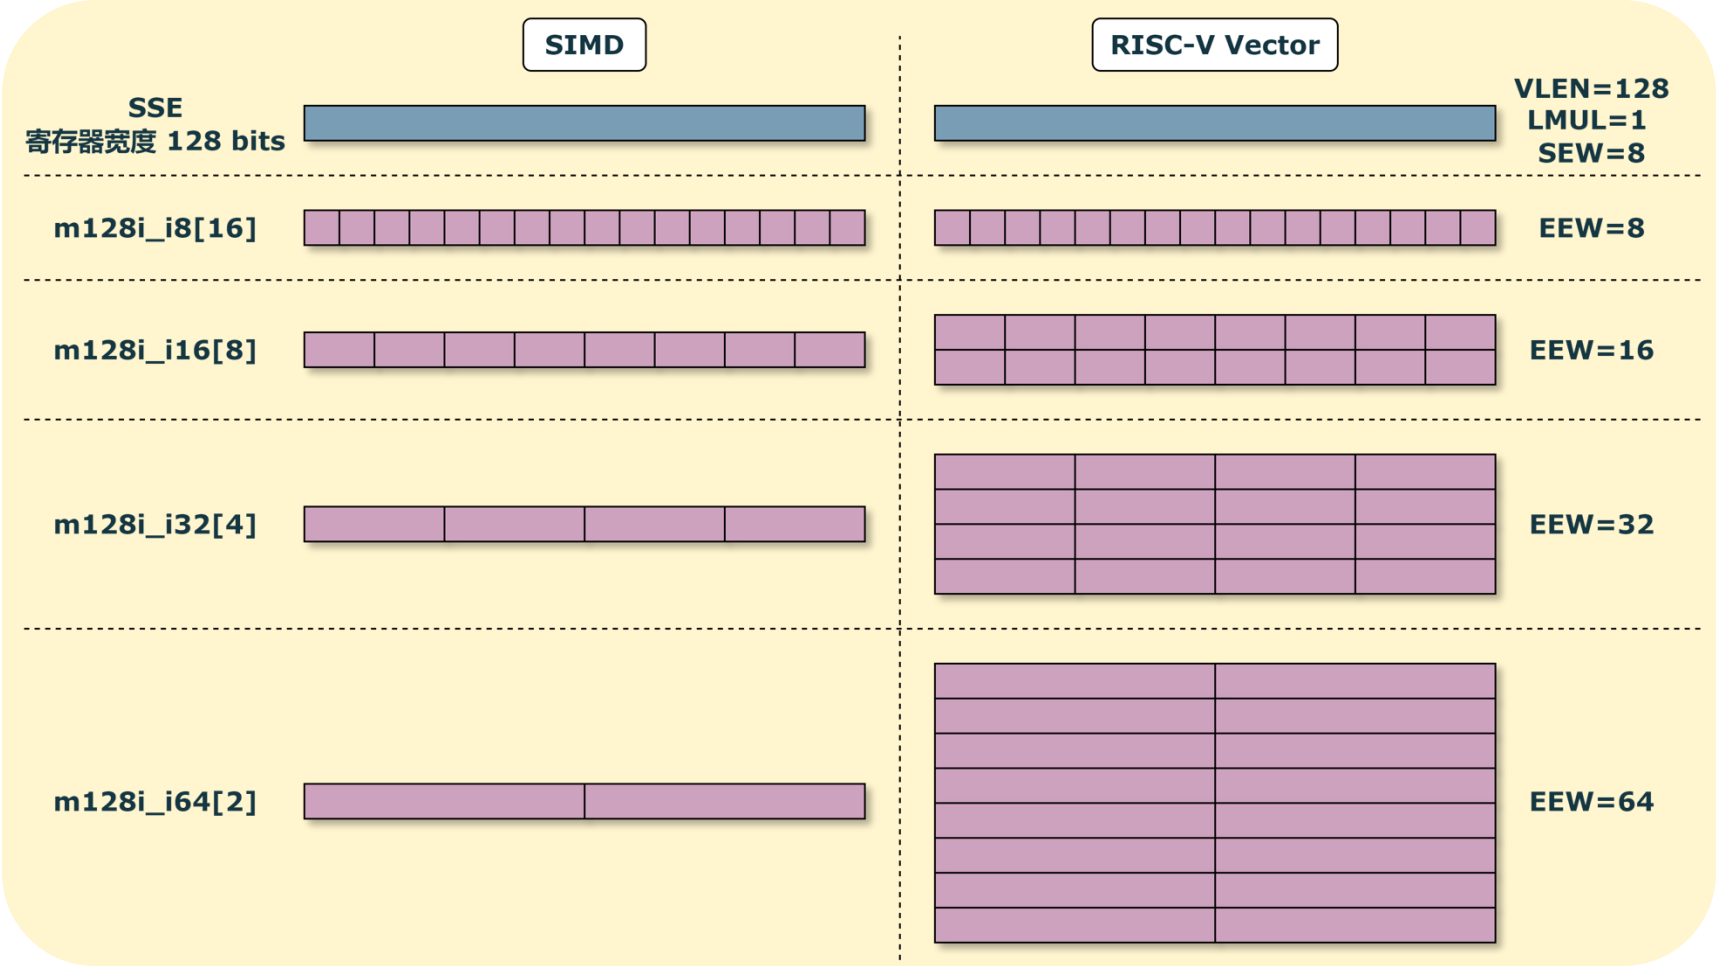

背景：RISC-V 向量计算技术

- 寄存器组：一条指令操作多个向量寄存器组 → 提高运算并行度
- **可变长向量长度**：指令与向量寄存器宽度无关 → **软硬件解耦**

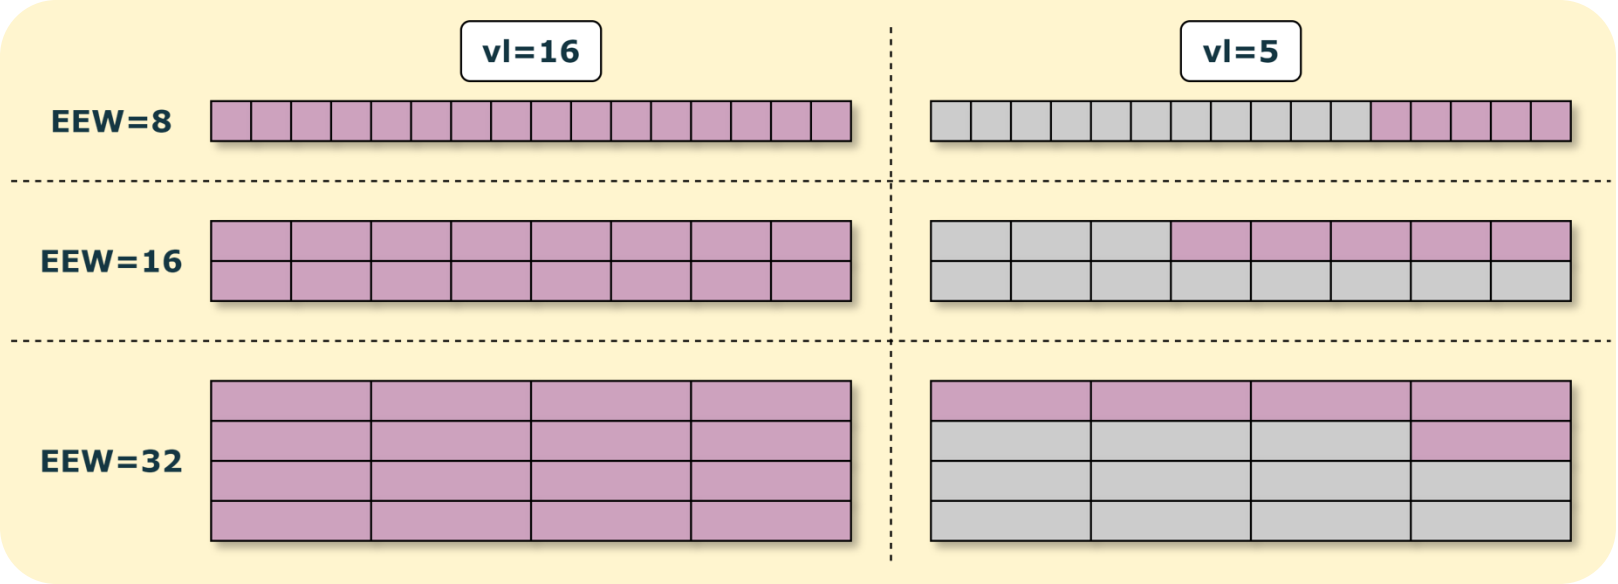

背景：RISC-V 向量计算技术

- **寄存器组**：一条指令操作多个向量寄存器组 → **提高运算并行度**
- **可变长向量长度**：指令与向量寄存器宽度无关 → **软硬件解耦**
- **谓词操作**：通过掩码对特定元素操作 → **方便稀疏数据处理**

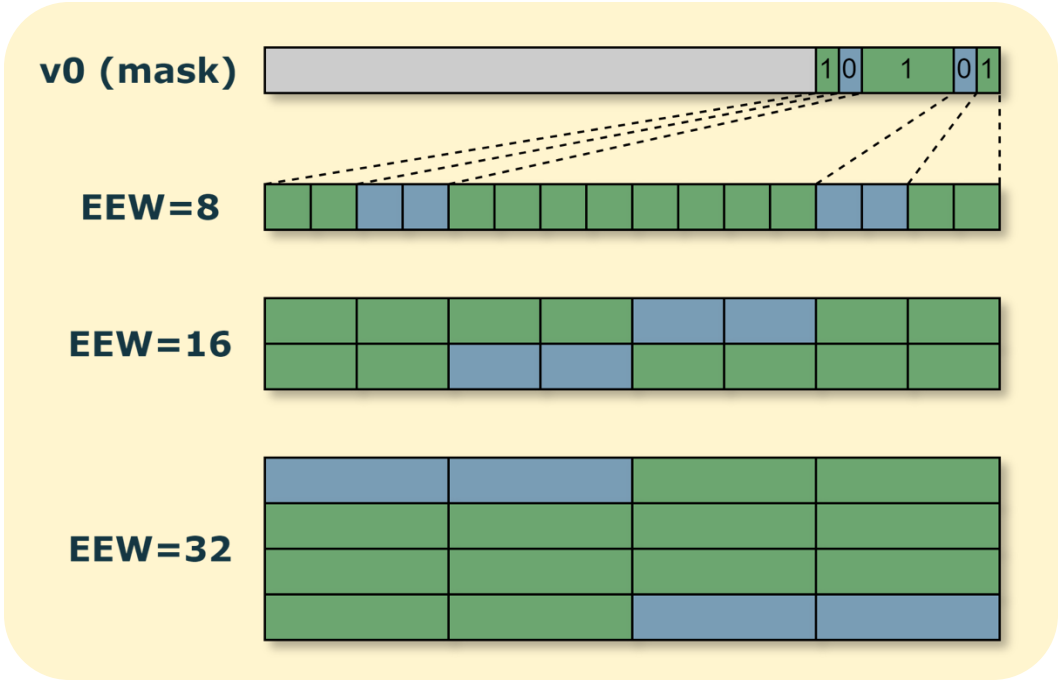

背景：RISC-V 向量计算技术

- **寄存器组**：一条指令操作多个向量寄存器组 → **提高运算并行度**
- **可变长向量长度**：指令与向量寄存器宽度无关 → **软硬件解耦**
- **谓词操作**：通过掩码对特定元素操作 → **方便稀疏数据处理**
- **丰富的访存模式**：支持多种向量访存操作

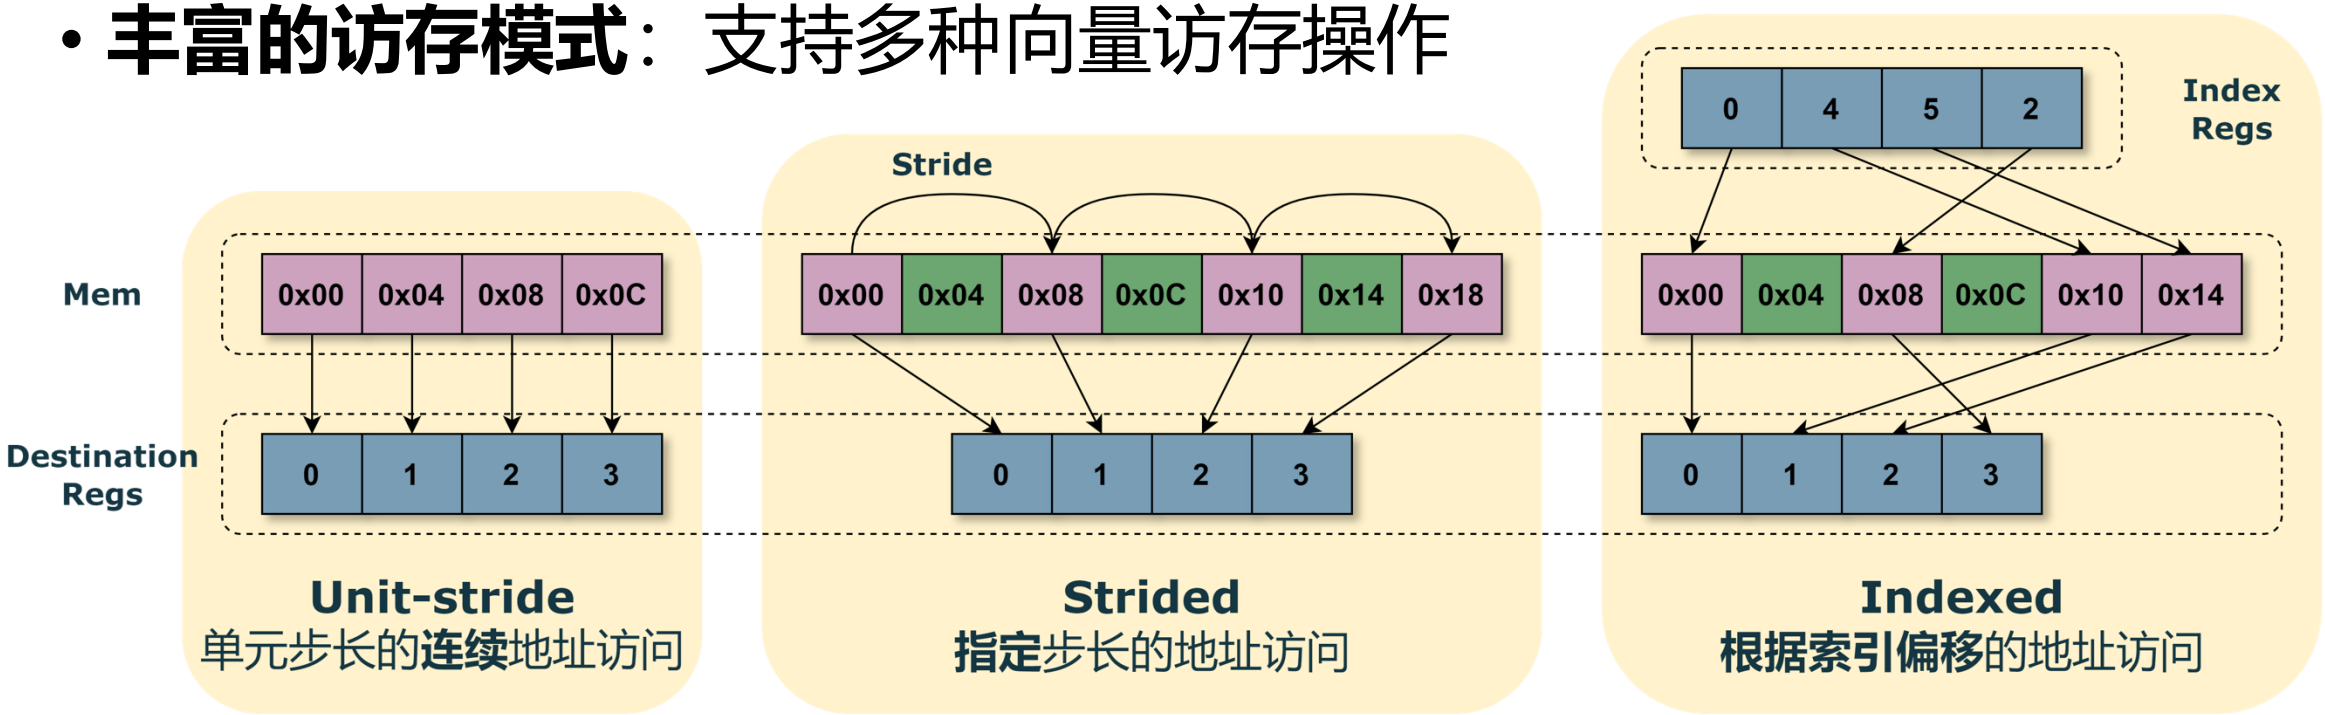

目录

- 背景介绍
- 香山向量扩展设计
- 高性能向量扩展设计演进
- 总结

香山处理器向量后端整体介绍

- 译码阶段拆分向量指令
- 独立的向量发射队列
- 分离的向量寄存器堆

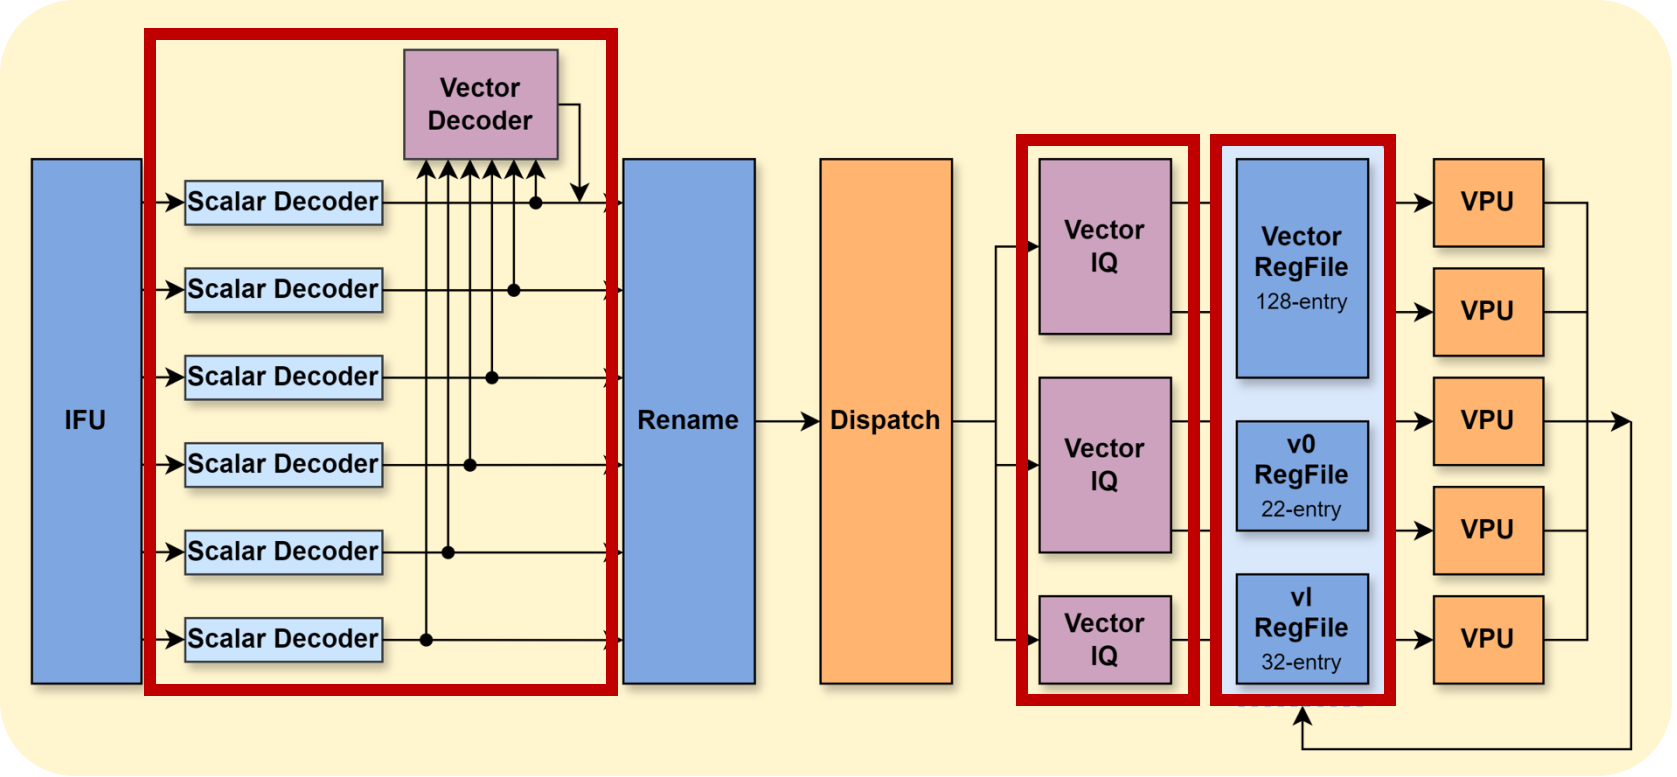

向量指令拆分：Uop (Micro-operation)

- **问题**
  - 一条向量指令需要处理多个向量寄存器
  - 运算单元每周期能处理的数据量有限（VLEN = 向量寄存器宽度）

- **目标：简化设计 + 复用标量流水线**

- **解决方案：每条指令以向量寄存器为粒度拆分为若干 Uop**
  - Uop 之间并行执行
  - Uop 内部元素并行执行

向量指令拆分：难点

- 某些向量指令需要获取标量操作数
  - ① 标量寄存器堆与向量寄存器堆彼此**独立**，且距离较远
  - ② 向量指令操作数来自**标量寄存器**或**立即数**时，需进行元素**复制填充**操作
- 解决方案
  - 添加一个用于**数据搬运的 Uop**
    - **读标量**寄存器堆
    - 元素复制填充
    - **写向量**寄存器堆

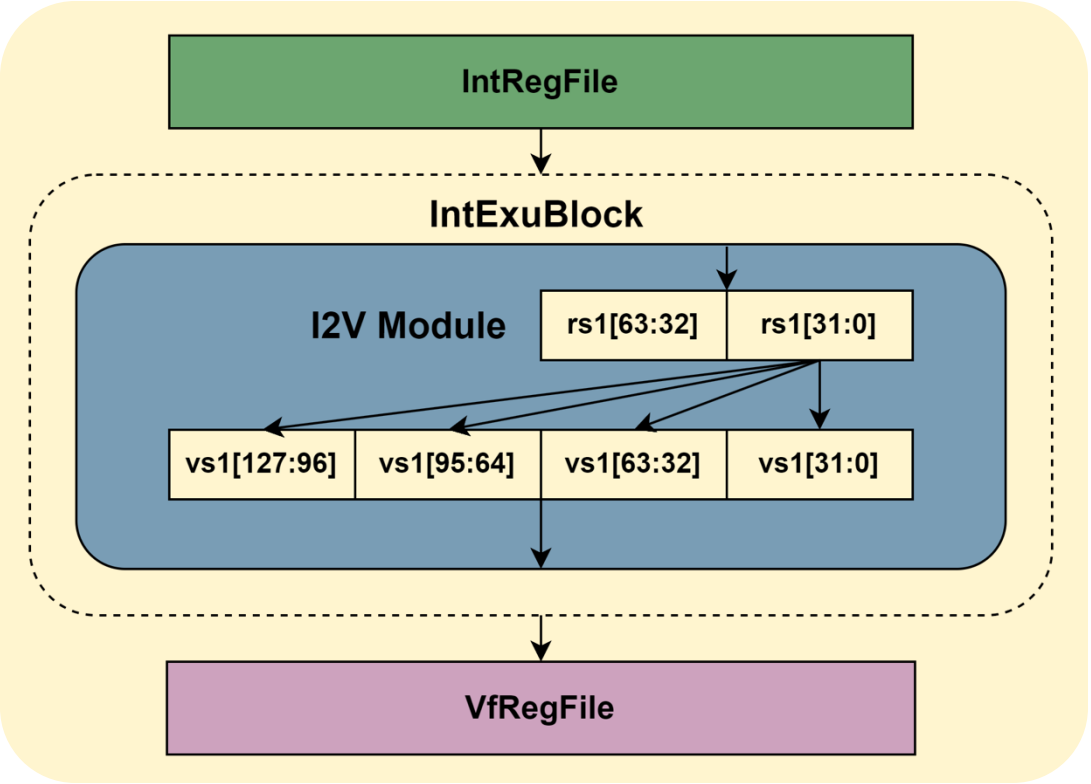

向量指令拆分：样例

- 向量运算指令拆分
  - **vadd.vx v4, v6, s2**
  - **vlmul = 2, vsew = 32, vl = 8**
  - 拆分出 **3** 个 Uop
    - 1 个 move Uop
    - 2 个 vadd Uop

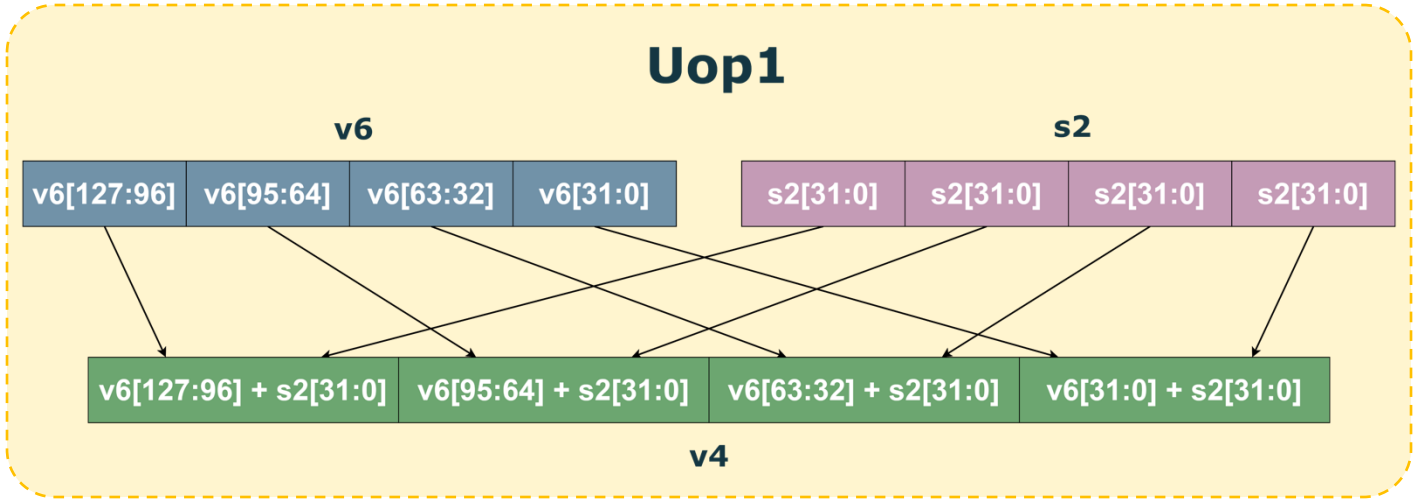

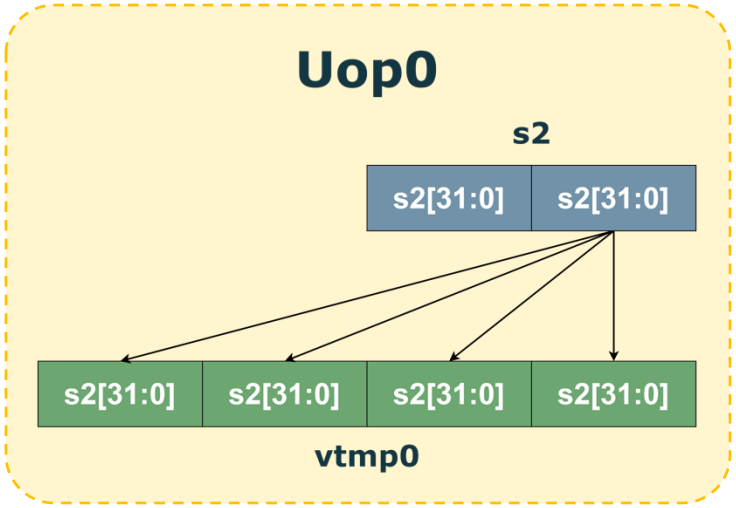

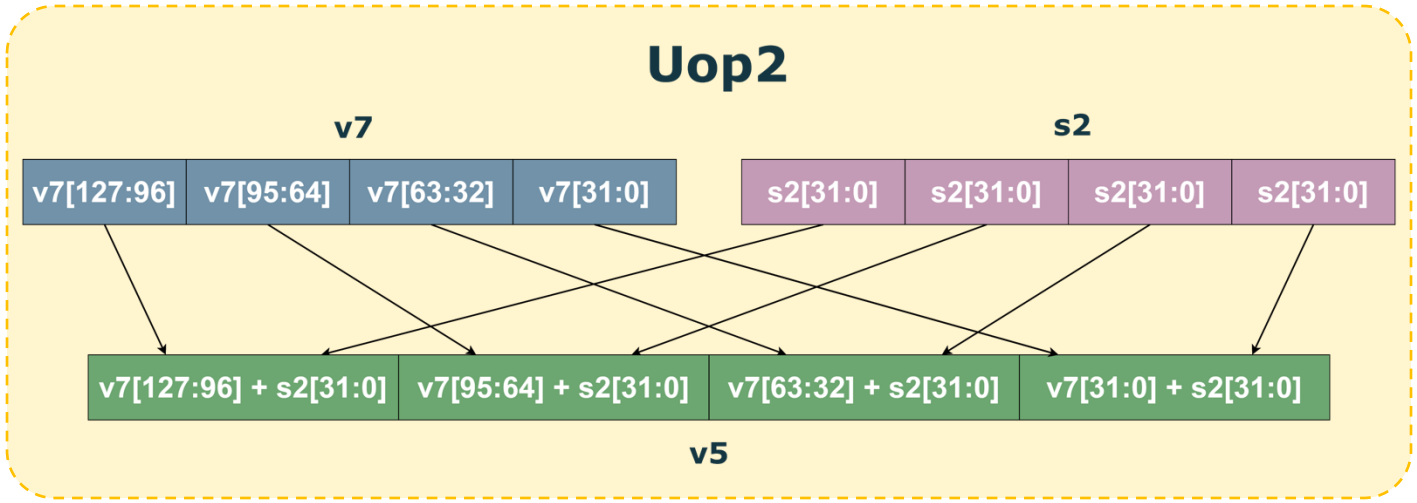

向量寄存器堆拆分

- 向量指令至多占用 5 个寄存器读口
  - 源寄存器 * 2
  - 目的寄存器
  - 谓词化掩码（v0）
  - 向量长度（vl 重命名以避免控制依赖）

向量寄存器堆	vec 寄存器堆	v0 寄存器堆	vl 寄存器堆
项数	128	22	32
读口	**12**	**4**	**4**
写口	6	6	2

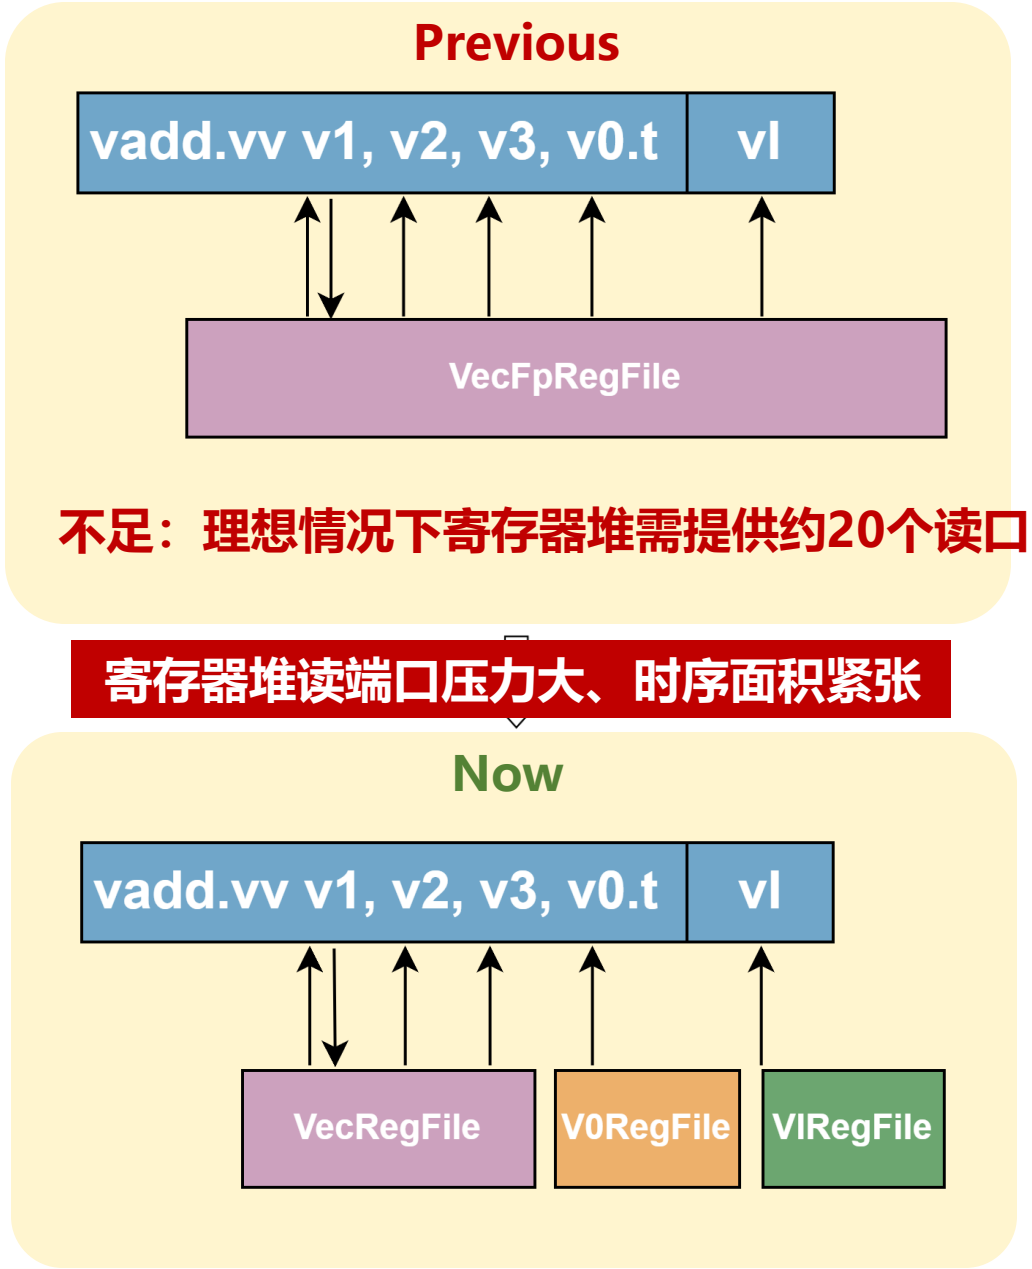

香山处理器向量访存整体介绍

- 混合的发射队列
- 按元素再次拆分 Uop
- 复用标量流水线
- 按 Uop 写回

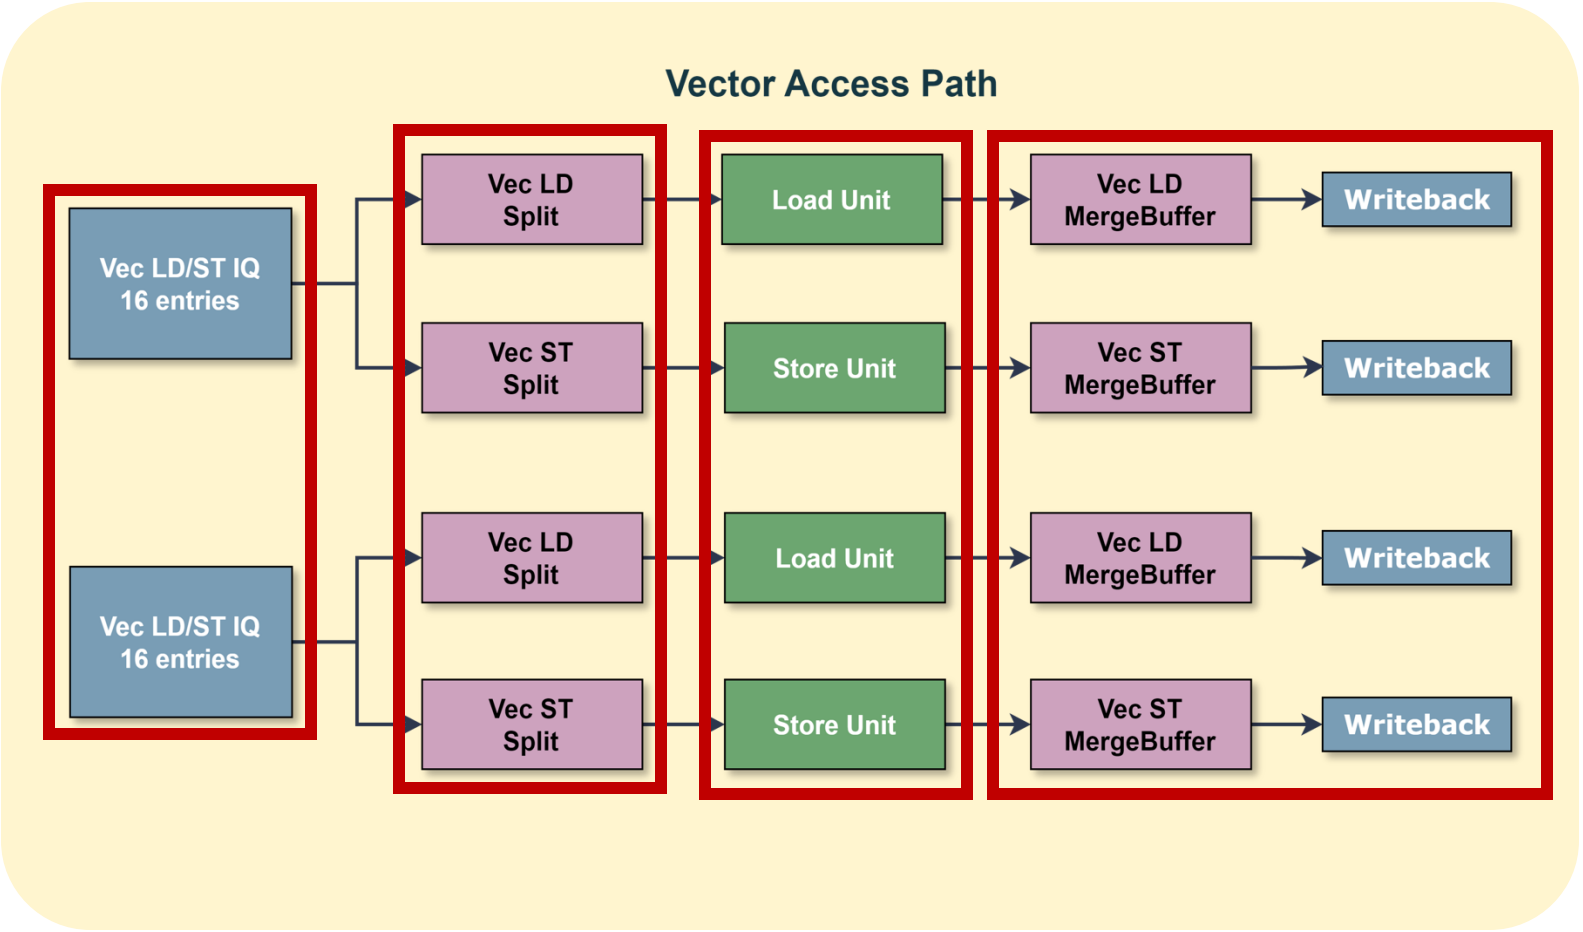

向量访存指令拆分

- 访存指令元素地址计算模式复杂
- 向量访存指令的两阶段指令拆分
  - 译码单元以目的 **寄存器** 为粒度进行拆分 (inst -> uop)
  - 向量访存单元以 **访存操作** 为粒度进行二次拆分 (uop -> flow)

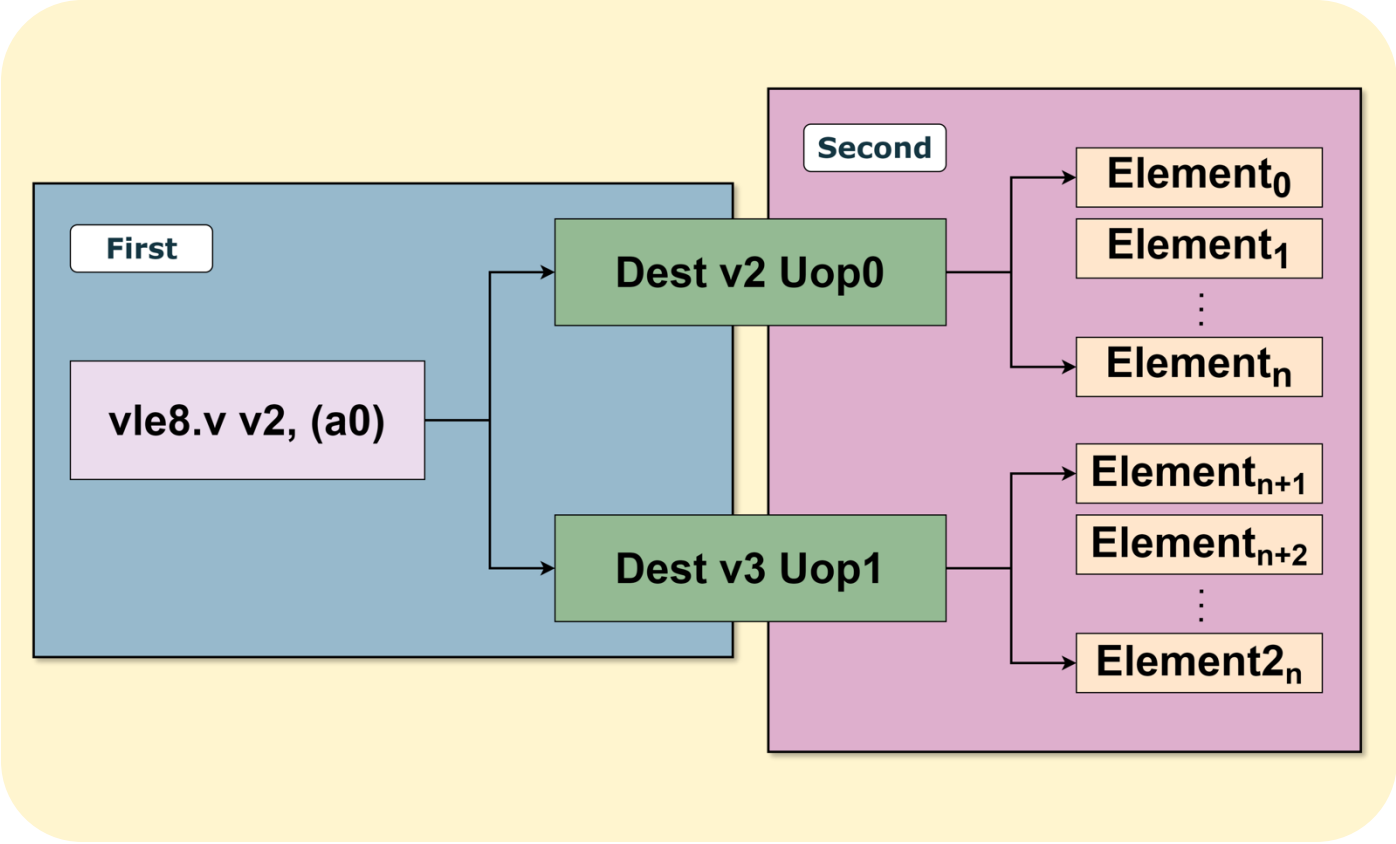

向量访存乱序执行流程

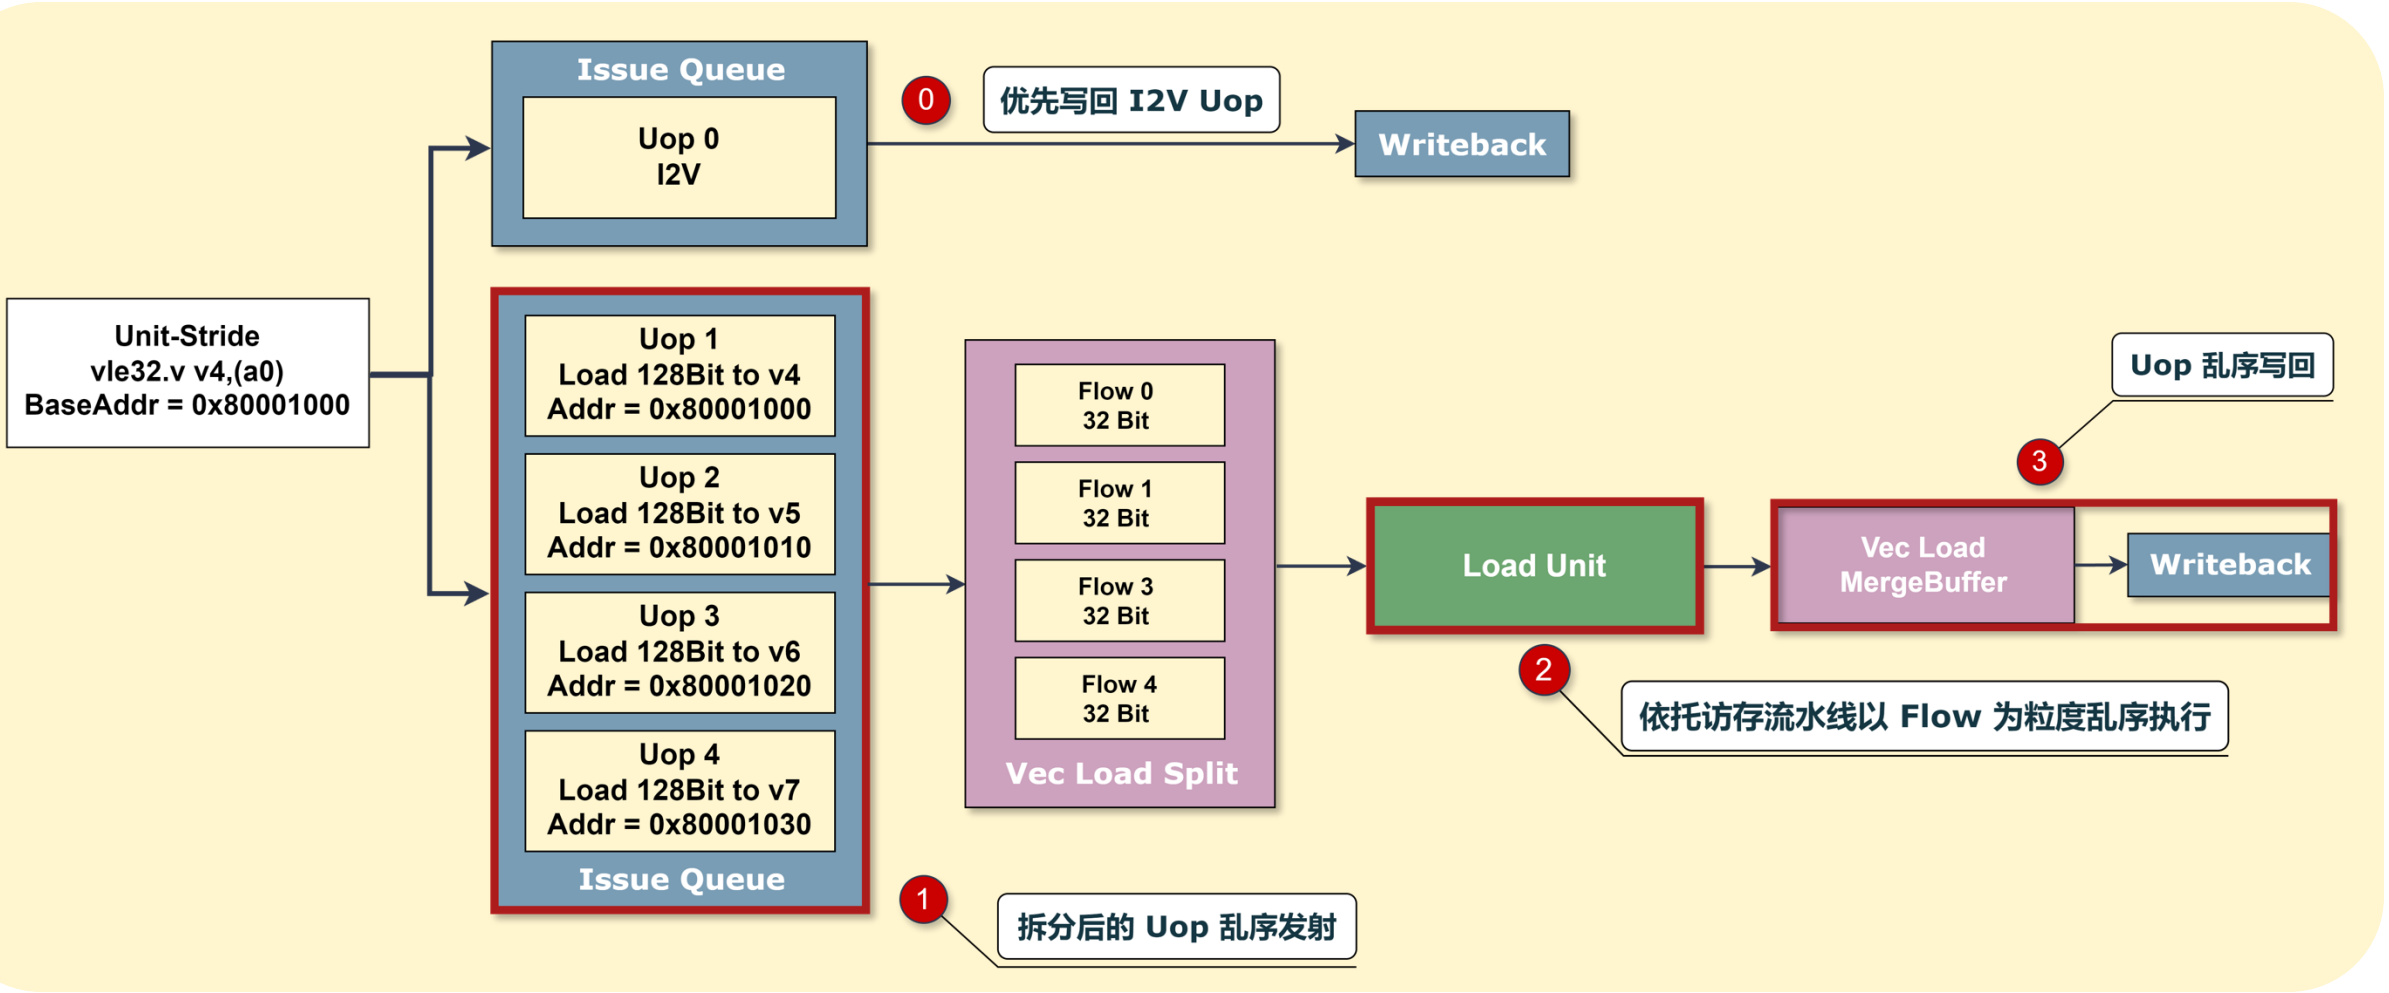
Issue Queue
Uop 0
I2V
0
优先写回 I2V Uop
Writeback
Unit-Stride
vle32.v v4,(a0)
BaseAddr = 0x80001000
Uop 1
Load 128Bit to v4
Addr = 0x80001000
Uop 2
Load 128Bit to v5
Addr = 0x80001010
Uop 3
Load 128Bit to v6
Addr = 0x80001020
Uop 4
Load 128Bit to v7
Addr = 0x80001030
Issue Queue
Flow 0
32 Bit
Flow 1
32 Bit
Flow 3
32 Bit
Flow 4
32 Bit
Vec Load Split
Load Unit
Vec Load
MergeBuffer
Writeback
Uop 乱序写回
3
2
依托访存流水线以 Flow 为粒度乱序执行
1
拆分后的 Uop 乱序发射

目录

- 背景介绍
- 香山向量扩展设计
- 高性能向量扩展设计演进
- 总结

优化一：消除向量配置指令 (vset) 控制依赖

- 性能瓶颈：
  - 向量循环体会频繁使用 vset 指令修改配置
  - vset 指令会修改 vtype 等 CSR

vset 修改 CSR 造成控制依赖

- 如何消除控制依赖？
  - 方法一：阻塞流水线
  - **方法二：推测执行**

```
.L4:    vsetvli  a5,a1,e32,m8,ta,ma
        vle32.v  v8,0(a7)
        vle32.v  v16,0(a6)
        sub      a1,a1,a5
        sh2add   a7,a5,a7
        sh2add   a6,a5,a6
        vmul.vv  v8,v8,v16
        vse32.v  v8,0(a2)
        sh2add   a2,a5,a2
        bne      a1,zero,.L4
        add      a6,t5,a0
```

矩阵点乘自动向量化汇编

优化一：消除向量配置指令 (vset) 控制依赖

- 向量配置寄存器 (vtype)
  - **推测更新**
    - **译码阶段**维护推测状态的 vtype
  - **错误恢复**
    - 流水线刷新时，使用 VType Buffer 保存的准确 vtype 恢复推测状态的 vtype
  - **CSR 寄存器更新**
    - vset 指令在**提交阶段**，从 VType Buffer 中获取 vtype，写入 CSR

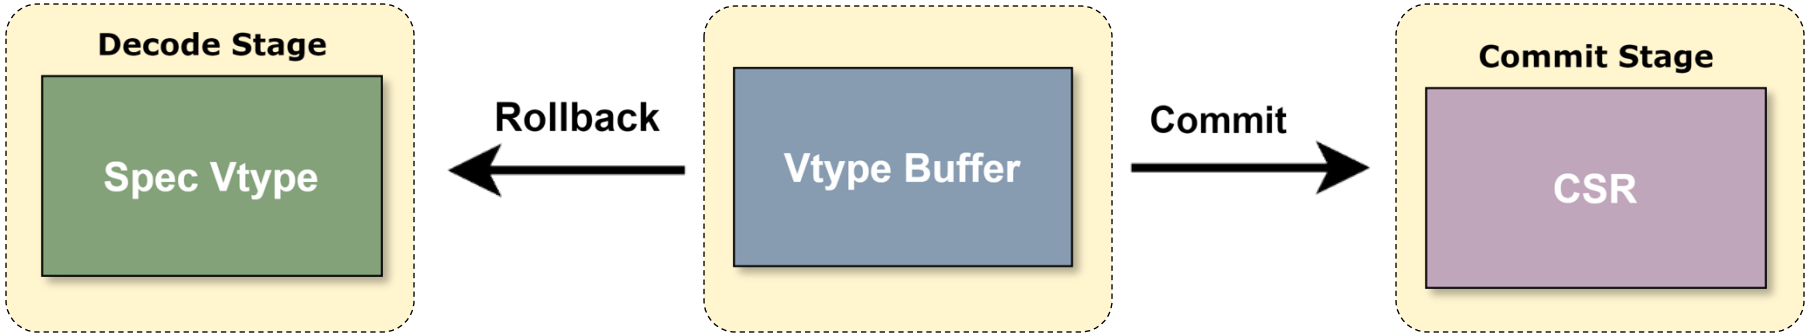

优化二：消除假数据依赖

- 向量指令可能只操作寄存器的一部分
- 不操作的部分可能需要保持旧值

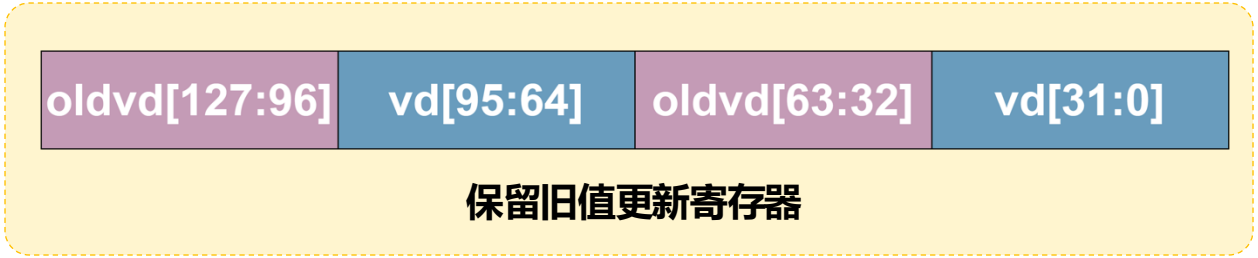

数据依赖降低执行并行度：

读取寄存器旧值可能导致假数据依赖

- 解决方法：软件层面消除旧值依赖
  - 软件配置**元素不可知** (Agnostic)
  - **也需要硬件实现的支持**

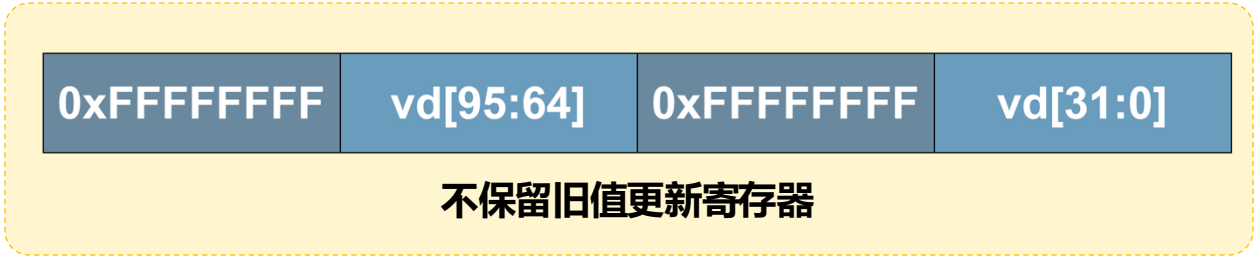

优化二：消除假数据依赖

- 硬件实现
  - 元素不可知策略
    - 不可知的元素由硬件实现为填 1，无需保留旧值
  - 根据向量长度判断是否需要存在旧值
    - 在软件没有配置不可知策略的情况下，依旧能消除依赖

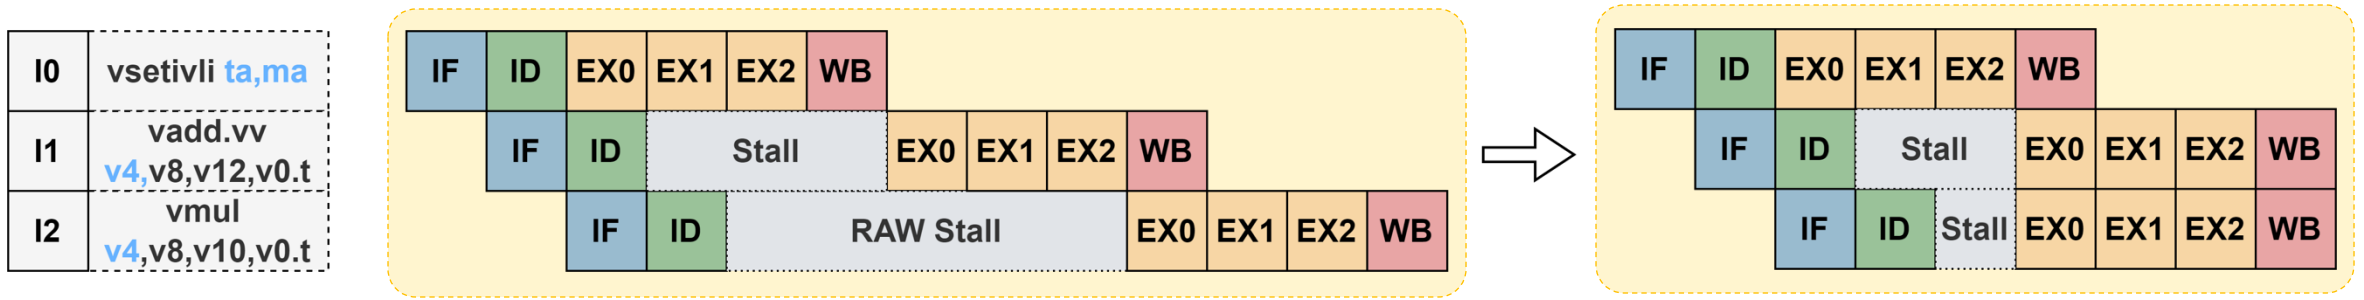

优化三：消除向量访存地址依赖

- 背景：大多向量化程序中标量访存指令与向量访存指令混合
  - 向量-向量、标量-向量、向量-标量都可能存在**地址依赖**

- 如何消除地址依赖？
  - 方法一：严格顺序访存

顺序访存会阻塞流水线、引入流水线空泡

  - **方法二：向量 Uop 拆分 + 标量访存违例检测 + 乱序访存单元**

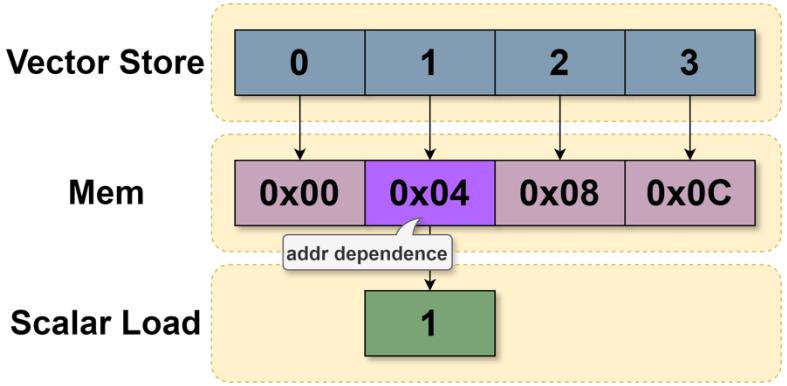

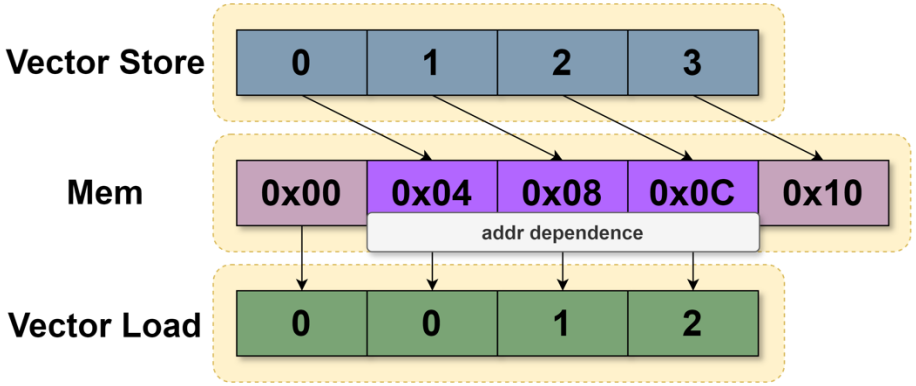

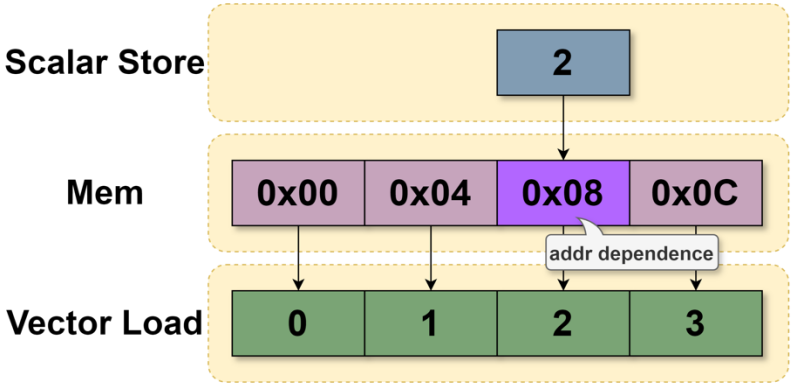

优化四：提高访存带宽

- 背景：Unit-Stride 指令访问**连续地址**的一段内存空间
- 拆分成单个元素访存时，如果元素位宽是 8 或者 16 等**小位宽数据**，则**难以**高效利用访存带宽

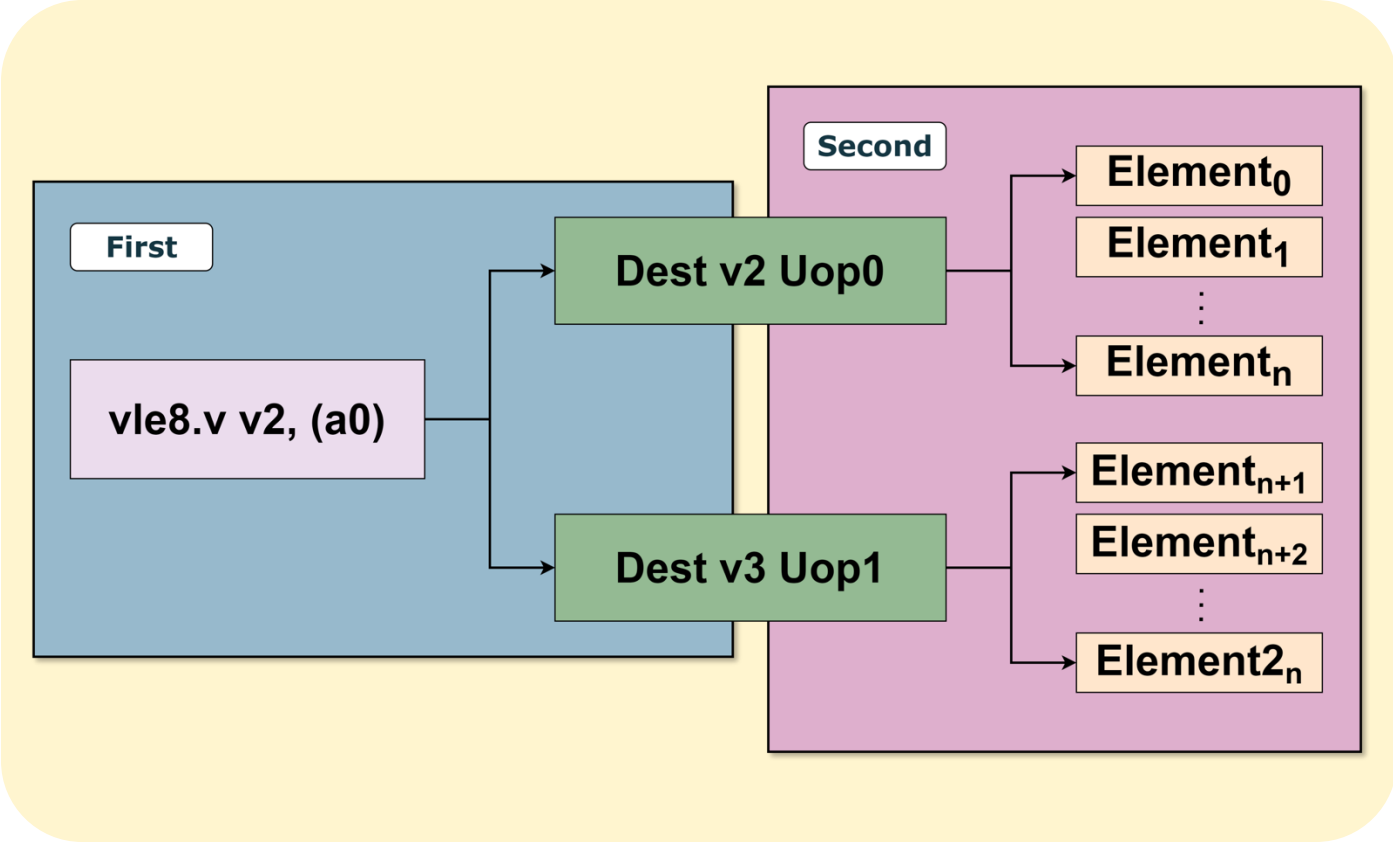

优化四：提高访存带宽

- 对于数据在内存中连续的 Unit-stride，在**不跨页**的情况下，只进行一次地址翻译与 cache 访问

- 一次能够直接访问 128-bits 数据

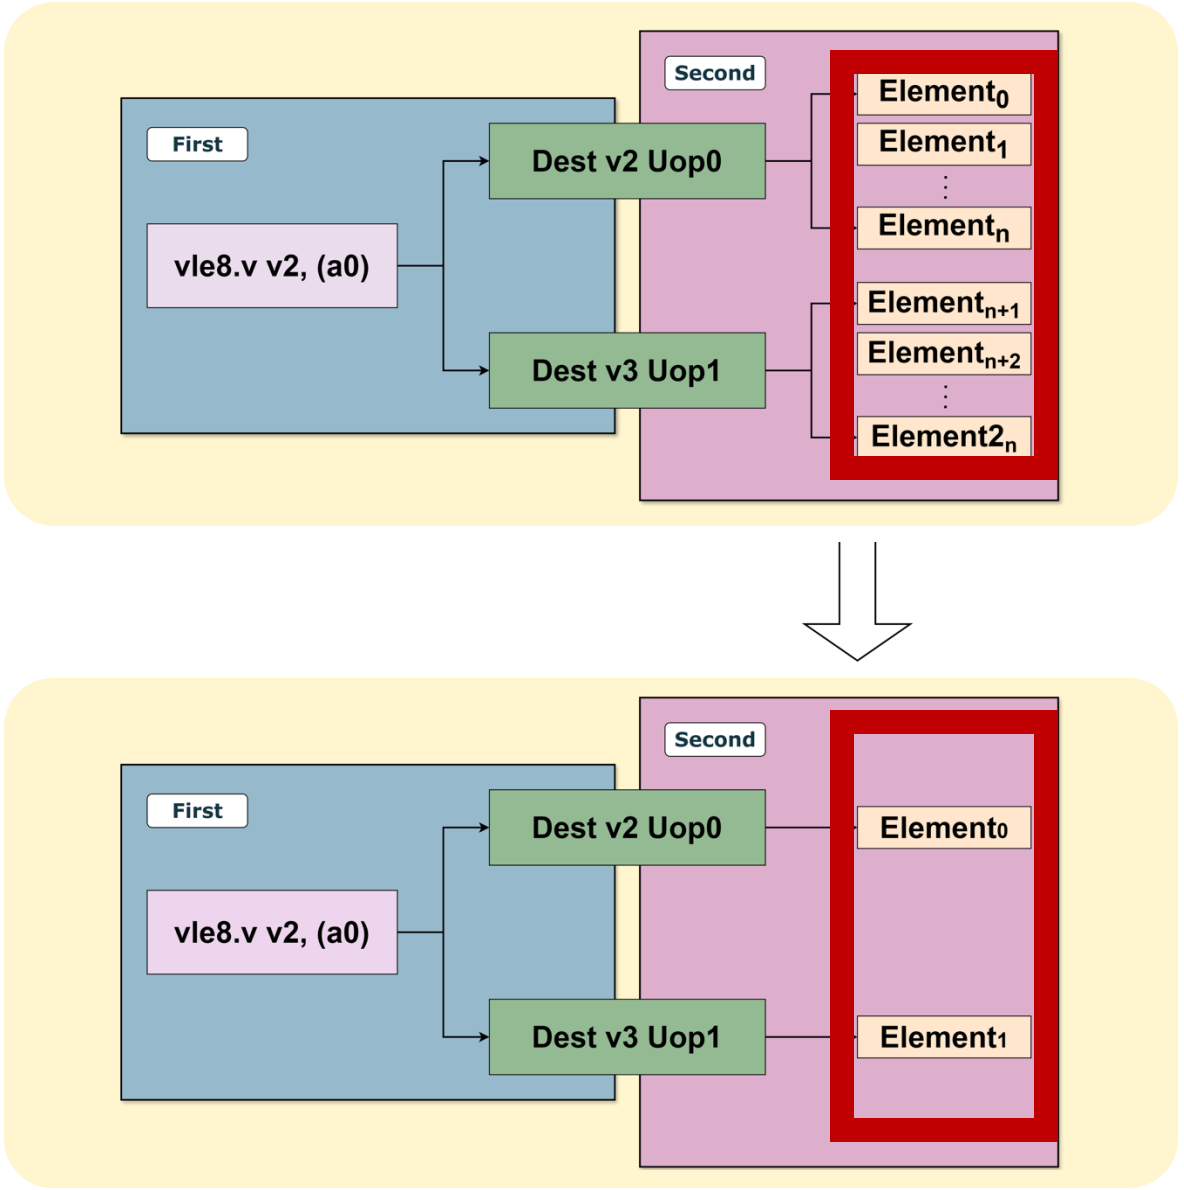

目录

- 背景介绍
- 香山向量扩展设计
- 高性能向量扩展设计演进
- 总结

总结

- 昆明湖向量扩展优化点总结
  - vset **控制依赖** — **vtype 推测机制**
  - 假**数据依赖** — **软硬件协同 数据依赖消除机制**
  - 访存**地址依赖** — **向量访存拆分 + 标量违例检测机制**
  - 访存**带宽**利用率低 — **Unit-stride 合并**

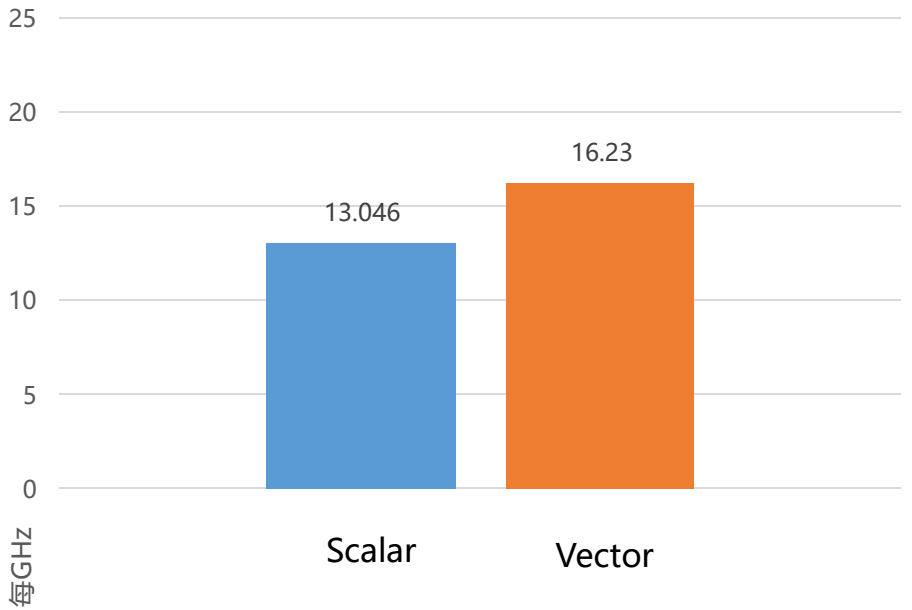

- SPEC CPU2006 456.hmmer 向量化性能与标量相比**提高 24.4%**

敬请批评指正！