

基于RISC-V向量拓展的高性能开源GPGPU设计

(股票代码: 688262)

苏州国芯科技股份有限公司

www.china-core.com





研发背景



▶ 发展背景:

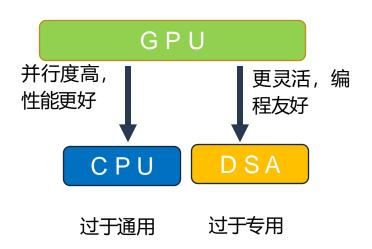
■ 通用图形处理单元 (GPGPU) 是高性能并行计算处理器芯片的一种。GPGPU因为其可编程性、易移植性,面对新兴应用具有更低的跟随成本,所以始终占据着高性能计算市场最大的份额。

痛点:

- GPU研发资源极度分散,内卷及其严重。
- GPU研发软件生态不够统一,各自封闭。

▶ 解决以上痛点

- 采用开源的RSIC-V架构实现GPU设计解决生态问题。
- 基于LLVM开发编译器,结合linker、runtime library、math library 实现对OpenGL、OpenGL ES、Vulkan和OpenCL C的完整支持。



GPU的核心就是生态,以上痛点也成为了国内GPU长远发展的瓶颈!



C GPGPU主要技术规格

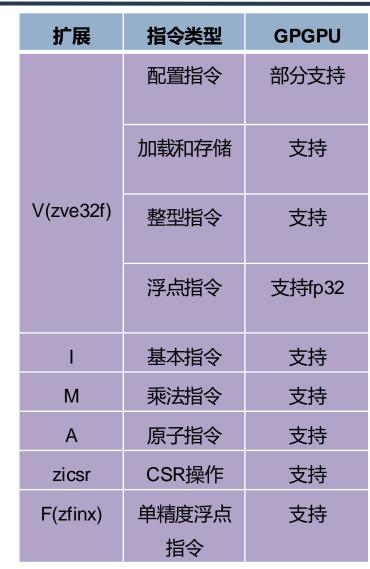


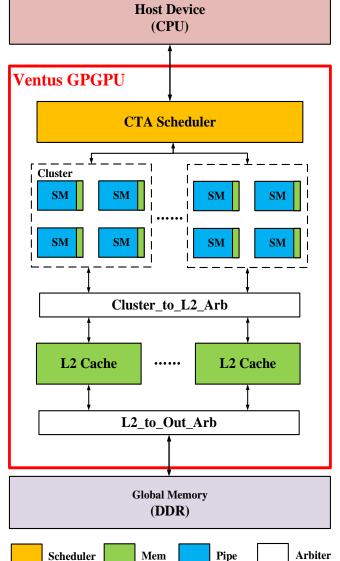
指令集架构

- RISC-V: RV32IMA_zicsr_zfinx + Vector 扩展
- 自定义线程束的分支和同步、多线程束执行指令
- 特性
 - 统一分配SM线程调度器CTA
 - 每个SM支持最大32线程
 - 支持Private、Share、Global存储模型
 - 支持256向量和64标量寄存器堆
 - 支持barrier、fence同步指令
 - 支持endprg、mask线程控制指令
 - 可配置Tensor Core

缓存架构

- "乘影"进一步部署了释放连贯 在RVWMO的基础上, 性指导的缓存一致性(RCC)。让SM私有缓存间具备 一致性功能的同时,避免了硬件一致性协议带来的高昂 硬件成本和运行时带宽开销
- 工程化RTL设计
 - Verilog语言设计





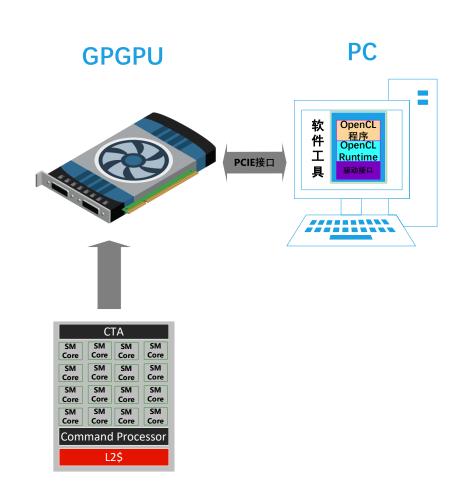


GPGPU主要技术规格



主要功能模块

- 1. 总调度器设计 (CTA Scheduler):
 - 负责以workgroup为单位接收CPU分配的总任务,并统计资源
 - 将任务以warp为单位逐个分配到空闲的SM上
- 2. 流多处理器设计 (SM):
 - 前端包括:取指、译码、指令缓冲、操作数收集、发射、记分牌、warp调度 (单指令操作)
 - 后端包括: ALU、vALU、vFPU、MUL、LSU、CSR、SFU、SIMT-stack、 TC、warp控制、写回(多线程执行)
- 3. 内存系统设计 (Cache):
 - 单个SM内部: Regfile、L1 DCache、L1 ICache、Share Mem
 - 多个SM共享L2 Cache



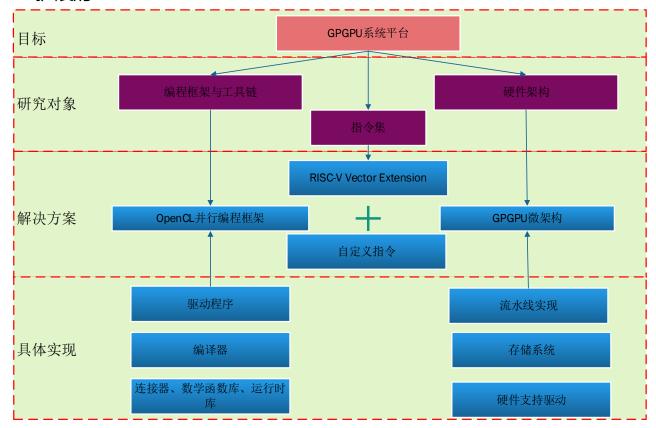


(GPGPU 研发平台简介



➤ 研发框架

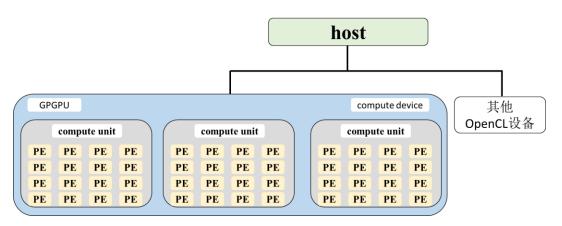
- 围绕开源RISC-V向量扩展搭建GPGPU平台,完成包括开源指令集、微架构设计、OpenCL软件工具链、专用张量计算单元在内的全套实现。
 - 参照开源软硬件项目"乘影" GPGPU平台而设计
 - 具有高度可定制性和可扩展性,具有完整的开源编译器,驱动程序和运行时软件堆栈
 - 是支持基于RISC-V ISA扩展的GPGPU



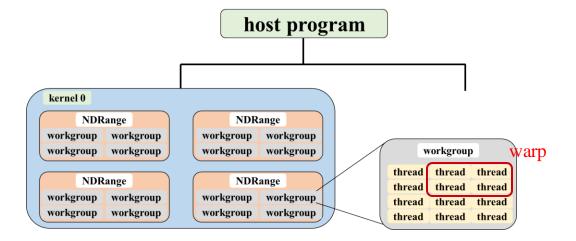


OpenCL编程模型

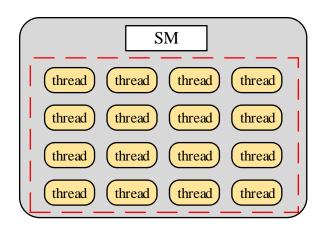




OpenCL平台模型



OpenCL执行模型

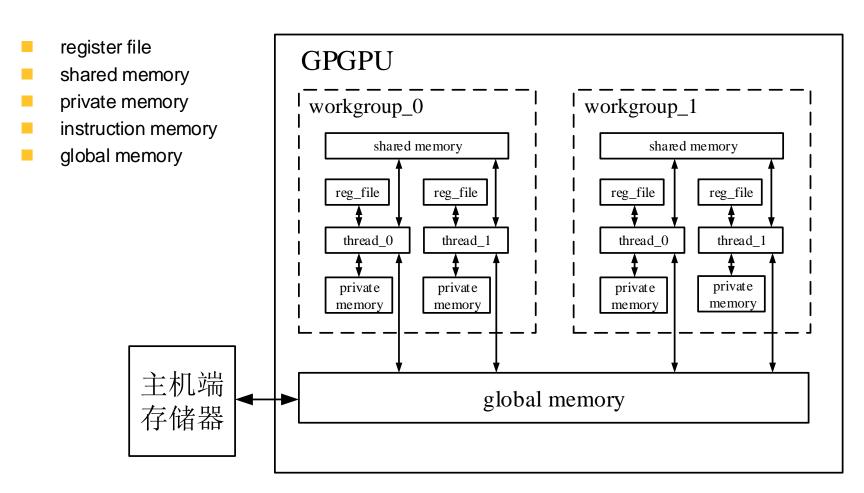


- workgroup被拆分成warp的形式在CU/SM内执行(1个 SM执行1个workgroup)
- warp: 单个SM内在硬件上有多少个线程
- 单个SM最多同时执行8个warp
- 同一warp中,所有线程运行相同的指令
- SM可以通过warp切换来掩藏延时





➤ 从软件视角看, GPGPU内部的存储资源包括:



Memory Space 0xFFFFFFF global memory thread私有 private memory instruction memory workgroup之间通信 shared memory 0x00000000



(自定义指令介绍

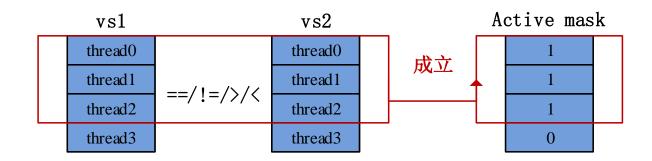


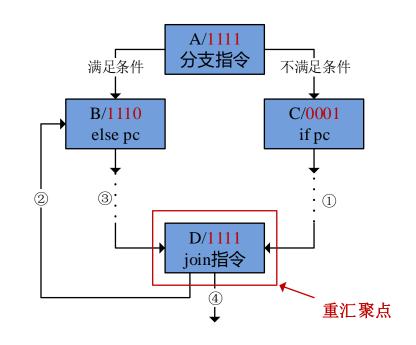
GPGPU支持SIMT执行模型,由硬件来管理分支

分支控制指令: vbeq/vben、vblt、vbge

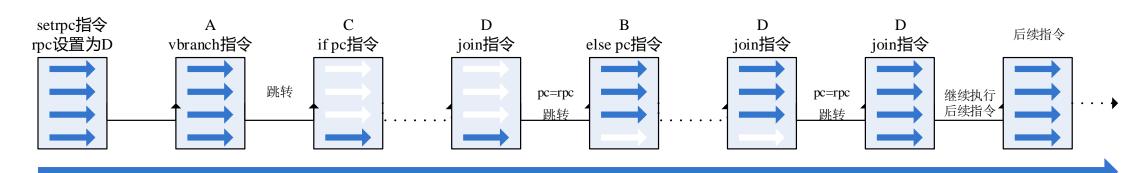
线程分支汇聚指令: join

重汇聚pc设置指令: setrpc





➤ 发生分支时,GPGPU的执行过程





自定义指令介绍



▶ 同步和任务控制指令

■ 栅栏指令: barrier

■ 线程退出指令: endprg

示例:

• barrier x0, x0, imm

• endprg x0, x0, x0: 用于指示当前warp已经执行结束

➢ 寄存器扩展指令: GPGPU需要索引比CPU更多的寄存器

under 立即数编码扩展: regexti

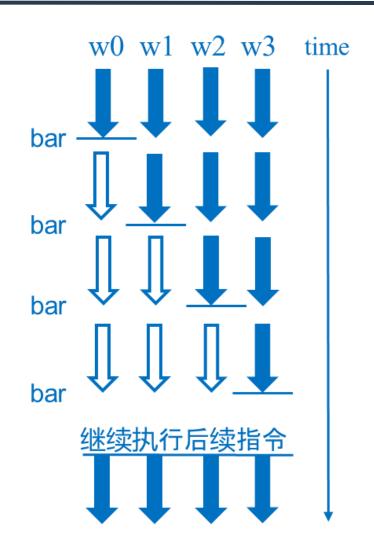
■ 寄存器编码扩展: regext

示例:

• regext x0, 0b000_001_000_010

vadd.vx v16, v20, x8

• 两条指令的执行结果等价于vadd.vx v80, v20, x40





自定义指令介绍



▶ 访存指令

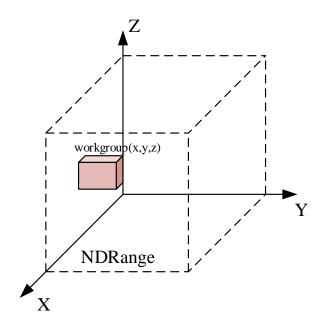
■ vlw12.v/vsw12.v: 支持addr=rs1+imm, 而非RVV的rs1+vs1

■ vlw.v/vsw.v:用于访问线程私有内存,与地址偏移thread_id有关

示例:

• vlw12.v vd, offset(vs1) 功能: vd = mem[addr], addr = vs1 + offset

• vlw.v vd, offset(vs1) 功能: vd = mem[addr], addr = (vs1+imm)*num_thread_in_wg+thread_idx+csr_pds



thread_idx:

	warp0	warp1		warp2		warp3		
0	31	32	63	64	95	96	12'	7



(自定义指令介绍



→ 计算指令

vadd12.v: 带12位立即数的向量帧数加减指令

vftta.vv: 张量计算指令

示例:

功能: vd = vs1 + imm • vadd12.vi vd, vs1

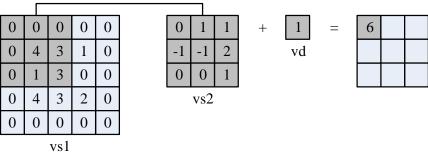
• vftta.vv vd, v2, v1, v0.mask 功能: vd = vs1 conv vs2 + vd

▶ 5*5的输入特征图与一个3*3的卷积核进行卷积:转换为矩阵乘积进行计算

0	0	0	0	4	3	0	1	3
0	0	0	4	3	1	1	3	0
0	0	0	3	1	0	3	0	0
0	4	3	0	1	3	0	4	3
4	3	1	1	3	0	4	3	2
3	1	0	3	0	0	3	2	0
0	1	3	0	4	3	0	0	0
1	3	0	4	3	2	0	0	0
3	0	0	3	2	0	0	0	0

	0		1		6
	1		1		-4
	1		1		-3
	-1		1		15
X	-1	+	1	=	2
	2		1		-1
	0		1		7
	0		1		1
	1		1		-4

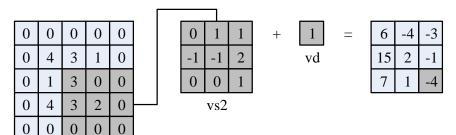
逐元素乘并累加



逐元素乘并累加

0	0	0	0	0	0	1	1	+	1	=	6	-4	
0	4	3	1	0	-1	-1	2		vd				
0	1	3	0	0	0	0	1						
0	4	3	2	0		vs2							
0	0	0	0	0									
		vs1			-								

逐元素乘并累加



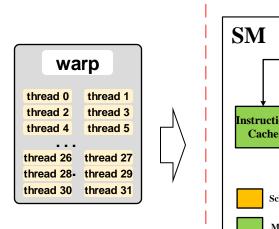
vs1

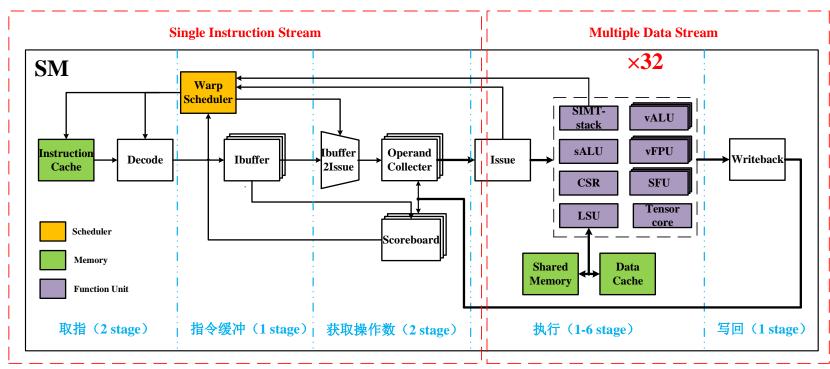




> SM流多处理器设计

- 支持多warp调度的RISC-V向量处理器
- 单个SM支持最多8个warp同时调度
- 单个warp支持最多32个向量同时执行



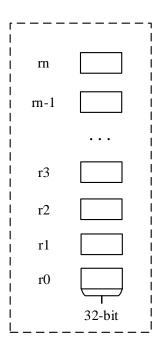


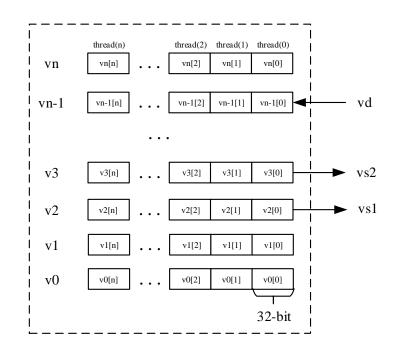




▶ 寄存器堆

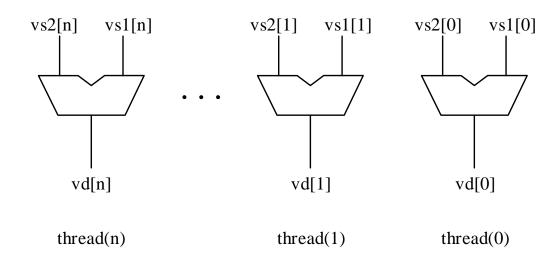
- SM内部有1024个sgpr和1024个vgpr
- 每个warp最多拥有256个sgpr和256个vgpr
- sgpr为warp内所有线程共有
- vgpr对应warp内各线程私有gpr





▶向量指令执行原理

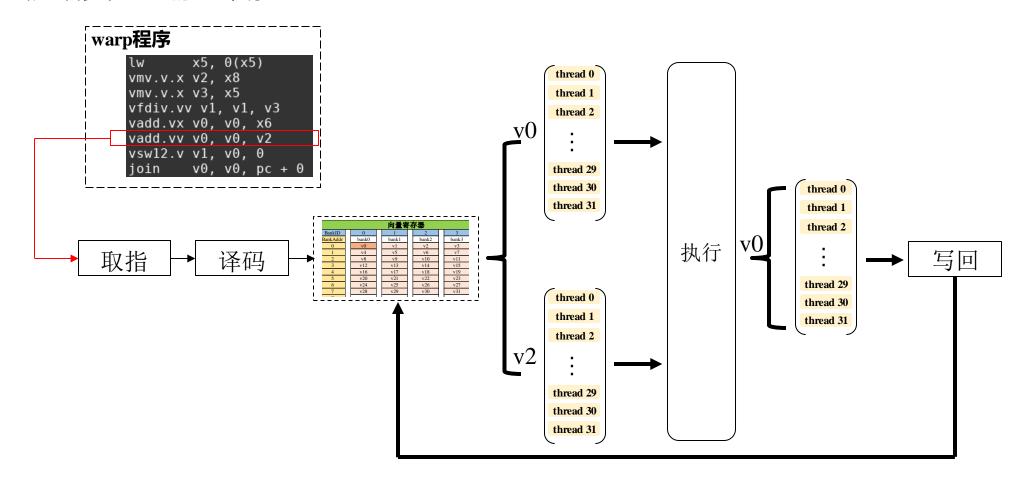
- 指令发送到执行单元后,按照SIMD的方式执行
- 从单个线程的角度看,执行的是标量指令。
- 执行结束后,所有线程的结果同时写回某一个向量寄存器中







一段包含多个thread的RVV程序

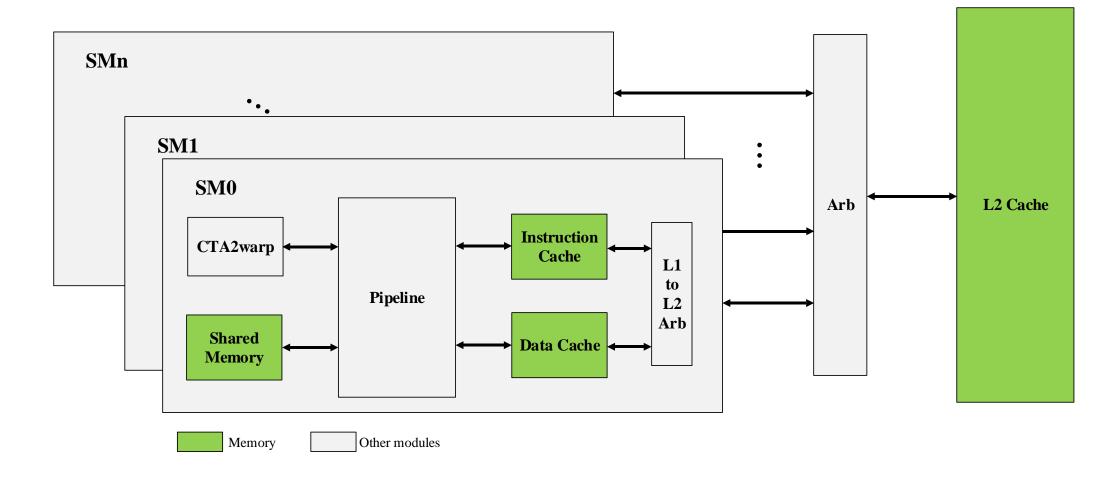






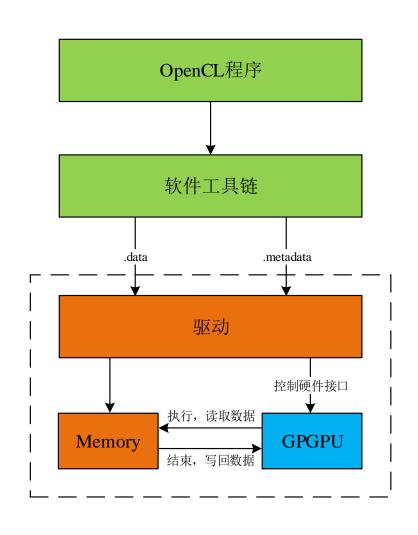
> 硬件存储结构

- shared memory用于仅用于SM内部通信
- private memory实际被保存在global memory中









测试平台:

- ① Testbench (Verilog) 模仿驱动行为,向GPGPU发起任务请求。
- ② GPGPU和Memory之间采用AXI4接口
- ③ .data: 硬件运行的指令和数据
- ④ .metadata: 指令和数据存放的地址,以及控制硬件接口所要包含的信息 (wg size, pds addr等)

Pattern分类:

- ① 针对不同的测试用例要编写不同的Testbench
- ② 不断添加边界测试用例



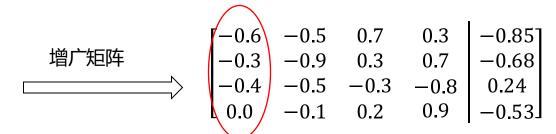
GPGPU 测试举例



➤ 以Gaussian消元举例

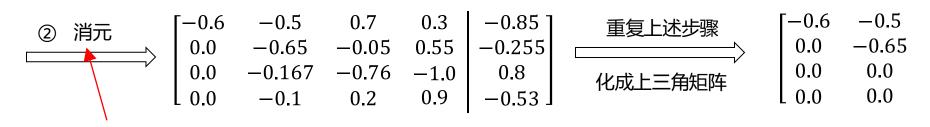
$$\begin{cases} -0.6x_1 - 0.5x_2 + 0.7x_3 + 0.3x_4 = -0.85 \\ -0.3x_1 - 0.9x_2 + 0.3x_3 + 0.7x_4 = -0.68 \\ -0.4x_1 - 0.5x_2 - 0.3x_3 + 0.80 = 0.24 \\ -0.1x_2 + 0.2x_3 + 0.9x_4 = -0.53 \end{cases}$$

开始执行前,将这个矩阵存入global mem



① 提取系数: 0.5, 0.67, 0

kernel0: GPGPU调用4个thread来完成计算,结果存入global mem



最终结果存入global mem

0.7

-0.05

-0.754

0.0

0.3

0.55

-1.14

0.501

 -0.85°

-0.255

0.872

-0.251

kernell: GPGPU调用16个thread来完

成计算,结果存入global mem



C*Core Technology Co.,Ltd.

▶ 性能评估

	SM	1			
	Wrap	8			
	Thread	32			
硬件配置	执行单元	32			
PCITAUL	L1 Icache	512B			
	L1 Dcache	512B			
	L2 Cache	64B			
工艺	T28, 9T cell, HVT & SVT				
综合频率	620MHz				
综合面积	1.93mm ²				

➤ 常用测试Pattern示例

测试集	warp/thread	是否通过	执行周期	说明
	4w16t	Pass	1800	64个元素向量加
vecadd: 向量加	4w8t	Pass	2696	32个元素向量加
vecaud: 回重加	4w32t	Pass	2164	128个元素向量加
	8w4t	Pass	2899	32个元素向量加
	1w32t	Pass	2801	4*4矩阵相加
matadd: 矩阵加	1w16t	Pass	2500	4*4矩阵相加
IIIalauu: AEP+AH	2w8t	Pass	2640	4*4矩阵相加
	4w4t	Pass	4054	4*4矩阵相加
	2w16t	Pass	2031	19个点中找最近的5个点
	4w8t	Pass	4033	28个点中找最近的5个点
nn: 最近邻内插法	4w16t	Pass	2269	53个点中找最近的5个点
	8w4t	Pass	3382	19个点中找最近的5个点
	8w8t	Pass	2038	53个点中找最近的5个点
	1w16t	Pass	10151	四元一次方程组消元
gaussian: 高斯消元	2w8t	Pass	11670	四元一次方程组消元
gaussian: 同利用儿	4w4t	Pass	11537	四元一次方程组消元
	4w8t	Pass	15940	五元一次方程组消元
	2w16t	Pass	20938	
Le 要由从上答注	4w8t	Pass	22730	
bfs: 宽度优先算法	4w32t	Pass	36114	
	8w4t	Pass	40888	

苏州国芯科技股份有限公司

www.china-core.com







最后, 愿国芯与您携手合作, 共创双赢!

C*Core

C*Core Technology Co.,Ltd.

重要声明:本公司致力于为客户持续提供自主可控高可靠芯片产品,产品规格如有变化,恕不另行通知,谨以最新技术资料及线下咨询为准。